

VYSOKÁ ŠKOLA BÁŇSKÁ – TECHNICKÁ UNIVERZITA OSTRAVA
EKONOMICKÁ FAKULTA



KATEDRA FINANCÍ

Využití analýzy sentimentu při predikci vývoje vybraných akciových titulů
Using Sentiment Analysis to Predict Movement of Selected Stocks

Student:

Bc. Petr Amler

Vedoucí diplomové práce:

doc. Ing. Aleš Kresta, Ph.D

Ostrava 2026

Obsah

1	Úvod	4
2	Teoretická východiska.....	6
2.1	Hypotéza efektivních trhů.....	6
2.1.1	Formy tržní efektivity.....	6
2.1.2	Dopady EMH na algoritmické obchodování.....	7
2.2	Behaviorální finance	8
2.2.1	Psychologické faktory v investičním rozhodování	8
2.2.2	Mean reversion a momentum jako tržní anomálie	9
2.3	Hypotéza adaptivních trhů	11
2.4	Tržní sentiment	12
2.4.1	Přehled existujících indexů sentimentu.....	13
2.4.2	CNN Fear & Greed Index	14
3	Metodologie a implementace modelu	19
3.1	Přehled metodologického rámce.....	19
3.1.1	Celková logika metodického postupu	19
3.1.2	Časový rozsah a datové zdroje	20
3.2	Metodika normalizace.....	22
3.3	Výběr a parametrizace komponent indexu	26
3.3.1	První komponenta - Market Momentum.....	26
3.3.2	Druhá komponenta - Stock Price Strength.....	27
3.3.3	Třetí komponenta - Stock Price Breadth.....	27
3.3.4	Čtvrtá komponenta - Put/Call Ratio	28
3.3.5	Pátá komponenta - Market Volatility	29
3.3.6	Šestá komponenta - Safe Haven Demand	29
3.3.7	Sedmá komponenta - Junk Bond Demand	30
3.4	Konstrukce kompozitního Fear & Greed Indexu.....	30
3.4.1	Váhové schéma a agregace	31
3.4.2	Validace rekonstrukce	32
3.5	Obchodní strategie založené na rekonstruovaném FGI	36
3.5.1	Klasifikace a přehled testovaných strategií.....	36
3.5.2	Jednotný rámec backtestingu a simulace obchodování.....	39
3.5.3	Matematická formulace obchodních strategií	41
3.5.4	Parametrizace strategií a grid search	42
3.5.5	Výkonnostní metriky a jejich výpočet	44
3.5.6	Validační schéma a benchmark.....	47

3.6	Implementace modelu v jazyku Python	48
3.6.1	Struktura projektu a datová vrstva	48
3.6.2	Implementace jednotlivých komponent indexu	48
3.6.3	Konstrukce a validace výsledného indexu	49
3.6.4	Implementace backtestingu a analýzy strategií	50
4	Výsledky empirické analýzy	52
4.1	In-sample optimalizace a výběr konfigurací pro out-of-sample validaci	52
4.2	Out-of-sample validace obchodních strategií a srovnání s benchmarkem...	54
4.2.1	Souhrnné out-of-sample srovnání	54
4.2.2	Kontrariánské strategie.....	56
4.2.3	Trendové strategie	58
4.2.4	Strategie založené na křížení klouzavých průměrů sentimentu	60
4.3	Srovnání konstrukčních variant strategií	64
4.3.1	Kontrariánská versus trendová interpretace sentimentu.....	64
4.3.2	Long-only versus combined přístup.....	65
4.4	Shrnutí výsledků ve vztahu k cíli práce	65
4.5	Diskuse výsledků ve vztahu k teorii a omezením práce	66
4.5.1	Diskuse výsledků ve vztahu k teorii.....	66
4.5.2	Omezení empirické části práce	67
5	Závěr.....	69
	Seznam použité literatury	70
	Seznam zkratk	73
	Seznam příloh	
	Přílohy	

1 Úvod

Finanční trhy nejsou utvářeny pouze ekonomickými fundamenty, ale také očekáváním, emocemi a kolektivním chováním investorů. Právě proto se v posledních desetiletích dostává do popředí zájmu investorů koncept tržního sentimentu, který zachycuje náladu na trzích. Vedle tradičního pohledu vycházejícího z hypotézy efektivních trhů se stále výrazněji prosazuje i přístup behaviorálních financí, podle něhož investoři nereagují vždy plně racionálně a psychologické faktory mohou vést k dočasným odchylkám cen aktiv od fundamentálních hodnot. Právě tyto odchylky mohou vytvářet příležitosti pro jejich využití na finančních trzích.

Jako výchozí ukazatel tržního sentimentu byl v této práci zvolen Cable News Network (CNN) Fear & Greed Index (FGI), a to především pro svou srozumitelnost a snadnou interpretaci. Na rozdíl od jiných ukazatelů sentimentu je zaměřen na americký akciový trh, je denně aktualizován a jeho konstrukce vychází z protikladu strachu a chamtivosti, tedy dvou emocí, které jsou s investičním rozhodováním úzce spojeny. Současně jde o kompozitní ukazatel, který kombinuje více signálů, a nezachycuje tak sentiment pouze prostřednictvím jediné proměnné. Jeho praktickým omezením je však krátká historie, protože časová řada indexu začíná teprve v roce 2011. Pro účely backtestingu je takové období poměrně krátké, zejména pokud má být dále rozděleno na optimalizační a validační část.

Z tohoto důvodu je stěžejní část práce věnována rekonstrukci CNN Fear & Greed Indexu zpět do roku 1998. Tím vzniká delší časová řada, která umožňuje zachytit nejen běžná tržní období, ale i období tržních turbulencí na americkém akciovém trhu. Pozornost proto není soustředěna pouze na samotné obchodní strategie, ale také na rekonstrukci tohoto indexu a na posouzení, nakolik takto vytvořená aproximace odpovídá historickým hodnotám. Teprve na tomto základě lze zkoumat, zda rekonstruovaný index může sloužit jako vstup pro obchodní strategie.

Cílem diplomové práce je rekonstruovat CNN Fear & Greed Index pro delší historické období a následně ověřit, zda lze takto rekonstruovaný indikátor sentimentu využít jako vstupní signál při tvorbě obchodních strategií. K naplnění tohoto cíle je nejprve nutné identifikovat a získat veřejně dostupné datové řady odpovídající jednotlivým komponentám indexu a připravit konzistentní datový základ pro jeho rekonstrukci za období let 1998 až 2026. Následně je navržen metodický postup

normalizace, parametrizace a agregace jednotlivých komponent a jsou sestaveny dvě varianty rekonstruovaného indexu, konkrétně varianta FGI s rovnoměrnými vahami (FGI_Equal) a varianta FGI s vahami odhadnutými metodou nejmenších čtverců (FGI_OLS). Dalším krokem je ověření kvality rekonstrukce porovnáním obou variant s hodnotami CNN Fear & Greed Indexu v období 2011 až 2026. Poté je navržen a implementován soubor obchodních strategií založených na rekonstruovaných indexech v jednotném backtestovacím rámci a je vyhodnocena jejich výkonnost v in-sample a out-of-sample období ve srovnání s benchmarkem Buy and Hold z hlediska výnosnosti a rizika.

Součástí diplomové práce je úvod, tři navazující kapitoly a závěr. Ve druhé kapitole jsou vymezena teoretická východiska vztahující se k hypotéze efektivních trhů, behaviorálním financím, adaptivní hypotéze trhů a problematice tržního sentimentu. Ve třetí kapitole je popsána metodologie rekonstrukce indexu, jeho validace a konstrukce obchodních strategií. Ve čtvrté kapitole jsou interpretovány empirické výsledky, shrnuty hlavní poznatky ve vztahu k cíli práce a diskutována omezení diplomové práce. V závěru jsou shrnuty hlavní poznatky práce.

Při zpracování diplomové práce byly využity nástroje umělé inteligence. Bližší specifikace jejich použití je uvedena v příloze č. 1. Zdrojové kódy použité při zpracování empirické části práce jsou uvedeny v příloze č. 2.

2 Teoretická východiska

Tato kapitola vymezuje teoretická východiska práce. Pozornost je soustředěna na hypotézu efektivních trhů, hypotézu adaptivních trhů, behaviorální finance a problematiku tržního sentimentu. Současně jsou stručně představeny vybrané přístupy k měření sentimentu a je charakterizován CNN Fear & Greed Index jako teoretický základ pro navazující metodickou a empirickou část práce.

2.1 Hypotéza efektivních trhů

Hypotéza efektivních trhů patří k zásadním konceptům moderní finanční teorie. Fama (1970) efektivní trh definuje jako trh, na němž ceny vždy plně odrážejí veškeré dostupné informace. Ve své navazující studii tuto myšlenku Fama (1991) zjednodušuje na výrok, že ceny cenných papírů v každém okamžiku zachycují vše, co je na trhu známo.

Fama (1991) však připouští, že takto silná verze hypotézy stojí na poněkud nerealistických předpokladech. Aby platila v plném rozsahu, musely by být transakční náklady i náklady na získání informací nulové, což jsou podmínky, které reálné trhy nesplňují. Proto nabízí ekonomicky přijatelnější alternativu. Ceny podle něj odrážejí dostupné informace pouze do té míry, dokud se to obchodníkům vyplatí, tedy dokud přínosy obchodování na základě dané informace nepřekročí náklady na její získání (Fama, 1991).

2.1.1 Formy tržní efektivity

Fama (1970) rozlišuje tři formy tržní efektivity podle toho, jakou množinu informací ceny odrážejí. První z nich je slabá forma efektivity, která předpokládá, že ceny aktiv plně zachycují veškeré historické cenové informace. Investoři tedy nemohou dosahovat nadprůměrných výnosů pouhou analýzou minulého vývoje cen.

Polosilná forma efektivity jde dále a rozšiřuje množinu relevantních informací na veškeré veřejně dostupné zdroje, jako jsou výroční zprávy, oznámení o hospodářských výsledcích nebo štěpení akcií. Klíčovou otázkou zde není to, zda ceny tyto informace odrážejí, ale jak rychle se jim přizpůsobují (Fama, 1991).

Třetí formou je pak silná forma efektivity, která předpokládá, že někteří investoři mají monopolní přístup k informacím relevantním pro tvorbu cen, jenž by jim umožňoval soustavně dosahovat nadprůměrných výnosů (Fama, 1970). Fama (1991) zároveň uvádí, že tato extrémní verze hypotézy je při existenci kladných nákladů na získávání informací

a obchodování nepravdivá. Její význam však neodmítá, protože ji chápe nikoli jako realistický popis fungování trhu, ale jako čistý teoretický benchmark, vůči němuž lze posuzovat, nakolik se skutečné trhy od ideálu efektivity odchylují.

Grossman-Stiglitz paradox

Ještě před tím, než EMH začala čelit kritice z pozic zastánců behaviorálních financí, identifikovali Grossman a Stiglitz (1980) v EMH rozpor. Pokud by ceny skutečně plně odrážely veškeré dostupné informace, neměl by žádný investor motivaci vynakládat prostředky na jejich získávání, protože by za to nezískal žádnou kompenzaci. Pokud by však nikdo informace nezískal, přestaly by být v cenách obsaženy. Grossman a Stiglitz (1980) proto docházejí k závěru, že předpoklad dokonalé informační efektivity a předpoklad nákladného získávání informací nejsou navzájem slučitelné. Místo dokonalé efektivního trhu proto navrhuji model, v němž ceny informace odrážejí pouze částečně, takže ti, kdo prostředky na jejich získání vynakládají, za to skutečně dostávají kompenzaci. Právě tato neúplnost přenosu informací do cen vytváří prostor, v němž mohou obchodní strategie postavené na veřejně dostupných datech, jako je Fear & Greed Index, systematicky fungovat.

2.1.2 Dopady EMH na algoritmické obchodování

Z hlediska algoritmického obchodování je nejdůležitějším důsledkem EMH takzvaná vlastnost fair game. Fama (1970) vysvětluje, že na efektivním trhu jednoduše neexistuje žádný obchodní systém postavený na dostupných informacích, který by dlouhodobě generoval nadměrné výnosy. Jakýkoli potenciální zisk totiž ostatní účastníci trhu rychle rozpoznají a obchodováním jej eliminují dříve, než ho lze soustavně využívat.

Pro strategii založenou na FGI z toho plyne implikace, konkrétně ve vztahu k polosilné formě efektivity. Fear & Greed Index je veřejně dostupný ukazatel přístupný každému investorovi bez omezení. Polosilná forma EMH přitom předpokládá, že ceny plně odrážejí veškeré veřejně dostupné informace. Pokud by tedy bylo možné na základě tohoto indexu systematicky dosahovat nadprůměrných výnosů, představovalo by to argument proti polosilné formě efektivity. Silná forma efektivity, kterou Fama (1991) sám označuje za neudržitelnou při existenci nákladů na získávání informací a obchodování, pro účely této práce relevantní není, protože zkoumané strategie nestojí na přístupu k neveřejným informacím.

Tato práce proto stojí na předpokladu, že psychologické faktory investorů vedou k předvídatelným odchylkám cen od jejich fundamentální hodnoty, a to i na základě veřejně dostupných dat. Právě tento prostor, který polosilná forma EMH teoreticky vylučuje, se tato práce pokouší algoritmicky využít.

2.2 Behaviorální finance

Behaviorální finance vycházejí z myšlenky, že investoři nejsou dokonale racionální a že jejich rozhodování je systematicky ovlivňováno psychologickými faktory. Shiller (2015) v tomto ohledu upozorňuje, že psychologický výzkum opakovaně odhaluje vzorce lidského chování, které by na dokonale racionálních trzích neměly vznikat. Nejde přitom o projev nevědomosti nebo neschopnosti jednotlivců, ale spíše o důsledek toho, jak lidská mysl funguje při rozhodování v podmínkách nejistoty. Behaviorální finance proto poskytují teoretický rámec pro vysvětlení toho, proč se ceny aktiv i rozhodování investorů mohou systematicky odchýlovat od předpokladů klasické finanční teorie.

2.2.1 Psychologické faktory v investičním rozhodování

V této podkapitole jsou vymezeny psychologické faktory, které ovlivňují investiční rozhodování a mohou přispívat k odchylkám cen aktiv od jejich fundamentálních hodnot. Pozornost je věnována přehnanému sebevědomí, stádovému chování, kotvení a averzi ke ztrátám.

Přehnané sebevědomí

Jedním z psychologických jevů v investičním rozhodování je sklon k přehnanému sebevědomí. Shiller (2015) uvádí, že lidé mají tendenci přeceňovat správnost vlastních úsudků. Tento sklon se podle něj projevuje tím, že lidé, i když svou odpověď považují za jistou, mívají pravdu přibližně pouze v 80 % případů. Shiller (2015) zároveň zdůrazňuje, že toto vychýlení směřuje spíše ve prospěch přehnaného sebevědomí než k jeho podcenění.

Konkrétní ilustraci tohoto jevu přináší Shillerův průzkum provedený bezprostředně po krachu akciového trhu 19. října 1987. Z individuálních investorů, kteří v tento den nakupovali, 47,1 % z nich uvedlo, že v určitém okamžiku mělo poměrně dobrou představu o tom, kdy dojde k obratu ve vývoji cen na trhu. U institucionálních investorů činil tento podíl 47,9 %. Shiller (2015) tento výsledek hodnotí jako pozoruhodný, protože stojí v rozporu s předpokladem, že je přesné časování trhu velmi obtížné.

Stádové chování

Významnou roli v investičním rozhodování hraje také stádové chování investorů. Shiller (2015) uvádí, že lidé, kteří spolu pravidelně komunikují, mají tendenci uvažovat podobně. Pokud se obdobné vzorce myšlení rozšíří mezi větší počet investorů, mohou se promítat i do vývoje tržních cen. Shiller (2015) zároveň upozorňuje, že stádové chování nemusí být jen důsledkem zjevně iracionálního jednání. Může vznikat i tehdy, když jednotlivci zohledňují úsudek ostatních a na jeho základě omezují vlastní nezávislé hodnocení situace. Tento mechanismus označuje jako informační kaskádu. Jejím důsledkem je, že informace o fundamentální hodnotě aktiv nejsou na trhu plně a nezávisle vyhodnocovány.

Kotvení

Dalším psychologickým jevem, který ovlivňuje investiční rozhodování, je kotvení. Shiller (2015) uvádí, že při úsudku v podmínkách nejistoty bývají odhady ovlivněny i zjevně nahodilými číselnými podněty. Na finančních trzích bývá za významnou kotvu považována především poslední známá cena aktiva. Jako další možné kotvy Shiller uvádí i dřívější ceny, nejbližší kulatá čísla významných indexů nebo nedávné cenové změny. V důsledku tohoto mechanismu mohou být ceny měněny postupně a tržní chování může být citlivé i na psychologicky významné cenové hladiny.

Averze ke ztrátám

Čtvrtým psychologickým jevem je averze ke ztrátám, kterou popsali Kahneman a Tversky (1979) v rámci Prospect theory. Její podstata spočívá v tom, že ztráty bývají vnímány silněji než stejně velké zisky. Autoři zároveň uvádějí, že lidé neposuzují výsledky absolutně, ale podle toho, zda je vnímají jako zlepšení, nebo zhoršení oproti své výchozí situaci.

2.2.2 Mean reversion a momentum jako tržní anomálie

Jak bylo uvedeno v podkapitole 2.1, slabá forma EMH předpokládá, že minulý vývoj cen by neměl umožňovat dosahování nadprůměrných výnosů. Empirická literatura však identifikovala některé anomálie, které s tímto předpokladem nejsou plně v souladu. Mezi nejčastěji diskutované tržní anomálie patří mean reversion a momentum.

Nadměrná reakce trhu a mean reversion

De Bondt a Thaler (1985) vycházejí z poznatků psychologie, podle nichž lidé při odhadu budoucího vývoje přikládají příliš velký význam nedávným a výrazným zprávám, zatímco delší předchozí vývoj berou v úvahu méně. Autoři proto zkoumají, zda se stejná tendence může projevit i na akciovém trhu. Na měsíčních datech akcií obchodovaných na burze New York Stock Exchange (NYSE) za období 1926 až 1982 sestavili portfolia předchozích vítězů a poražených, tedy akcií s nejlepší a nejhorší výkonností, a následně sledovali jejich vývoj v dalších třiceti šesti měsících. V hlavní analýze portfolia poražených překonala trh v průměru o 19,6 %, zatímco portfolia vítězů za trhem zaostala přibližně o 5,0 %. Rozdíl v kumulativních výnosech tak dosáhl 24,6 %. Výsledek naznačuje, že akcie, kterým se v předchozím období nedařilo, měly následně tendenci posilovat, zatímco dřívější vítězové spíše zaostávali. De Bondt a Thaler (1985) říkají, že tyto výsledky podporují hypotézu nadměrné reakce trhu a nejsou v souladu se slabou formou tržní efektivnosti.

Momentum efekt

Jegadeesh a Titman (1993) na akciích obchodovaných na burzách NYSE a American Stock Exchange (AMEX) v letech 1965 až 1989 ukazují, že akcie s lepší předchozí výkonností mají v krátkém období tendenci dále růst, zatímco akcie s horší předchozí výkonností dále zaostávají. Strategie založené na nákupu dřívějších vítězů a prodeji dřívějších poražených proto přinášejí statisticky významné kladné výnosy v období tří až dvanácti měsíců. Strategie, která vybírá akcie podle jejich výkonnosti v předchozích šesti měsících a drží je dalších šest měsíců, dosahuje přibližně 1 % měsíčně. Autoři zároveň uvádějí, že tuto ziskovost nelze jednoduše vysvětlit tím, že by šlo pouze o rizikovější akcie. Část tohoto efektu podle nich souvisí s tím, že se do cen se zpožděním promítají širší tržní vlivy, a část s tím, že se se zpožděním promítají i informace týkající se jednotlivých firem.

Sjednocení obou perspektiv

Na první pohled se může zdát, že si oba přístupy odporují. De Bondt a Thaler (1985) dokazují, že na delších horizontech tří až pěti let mají akcie s nejhorší předchozí výkonností tendenci následně překonávat akcie s nejlepší předchozí výkonností. Jegadeesh a Titman (1993) naopak zjišťují, že na kratších horizontech tří až dvanácti

měsíců akcie s lepší předchozí výkonností často ve svém růstu ještě určitou dobu pokračují. Zdánlivý rozpor tak spočívá především v odlišném časovém horizontu.

Z pohledu tržního sentimentu tak lze oba jevy chápat jako odlišné projevy toho, že ceny nereagují vždy zcela efektivně. Na kratších horizontech může pokračovat již nastolený trend, zatímco na delších horizontech může následovat korekce předchozího vývoje. Psychologické faktory tak mohou přispívat k dočasným odchylkám cen aktiv od jejich fundamentálních hodnot. Právě z toho vyplývá, proč jsou v této práci testovány jak kontrariánské, tak trendové strategie. Jejich konkrétní podoba je popsána v podkapitole 3.5.1.

2.3 Hypotéza adaptivních trhů

Lo (2004) představuje hypotézu adaptivních trhů (Adaptive Markets Hypothesis, AMH) jako přístup, který se snaží propojit hypotézu efektivních trhů s poznatky behaviorálních financí. Vychází přitom z evolučního pohledu na fungování finančních trhů. Podle tohoto přístupu se chování investorů i fungování trhu mění v závislosti na prostředí, konkurenci a zkušenosti účastníků trhu.

Důležitým východiskem tohoto pojetí je představa, že investoři nerozhodují jako dokonale racionální subjekty. Rozhodování investorů vychází spíše ze zkušeností, pokusu a omylu a z postupů, které se jim v minulosti osvědčily. Pokud se však podmínky změní, mohou přestat fungovat i obchodní pravidla, která byla dříve funkční. Chování, které se jeví jako chybné, proto nemusí být nutně projevem úplné iracionality, ale spíše důsledkem toho, že se investor dosud nepřizpůsobil novému prostředí.

Z toho plyne i odlišný pohled na tržní efektivitu. Lo (2004) ji nechápe jako stálou vlastnost trhu, ale jako jev, který se mění v čase. Záleží na tom, kolik různých skupin investorů na trhu působí, jak silná je mezi nimi konkurence a kolik ziskových příležitostí je k dispozici. Tam, kde o příležitosti soutěží větší počet účastníků trhu, může být efektivita vysoká. Naopak tam, kde je účastníků méně nebo je příležitostí více, může být efektivita nižší. Lo tuto proměnlivost ilustruje i na vývoji amerického akciového trhu, kde ukazuje, že míra efektivity se v čase mění a nevyvíjí se pouze jedním směrem. V některých obdobích padesátých let byl trh podle jeho ukazatele efektivnější než na počátku devadesátých let.

Stejná logika se podle Lo vztahuje i na obchodní strategie. Ty nemusí být trvale ziskové ani trvale nefunkční. Jejich výkonnost se může měnit podle toho, jak se mění

tržní podmínky, počet konkurentů i množství příležitostí. Strategie, která v jednom období selhává, se tak může v jiném období znovu ukázat jako funkční. Adaptive Markets Hypothesis se tím odlišuje od klasické EMH, v níž jsou ziskové příležitosti obchodníky postupně odstraňovány.

Pro tuto práci má Adaptive Markets Hypothesis přímý interpretační význam. Kontrariánské strategie založené na návratu cen k průměru proto nemusí fungovat stejně ve všech obdobích. Jejich výsledky mohou záviset na tom, zda na trhu převládá stabilnější prostředí, nebo naopak období zvýšené nejistoty a napětí.

2.4 Tržní sentiment

Jak bylo popsáno v předchozích podkapitolách, behaviorální přístup připouští, že se investoři nemusí rozhodovat plně racionálně a že se ceny aktiv mohou dočasně odchylovat od fundamentálních hodnot. Nabízí se proto otázka, zda lze tyto odchylky zachytit a měřit. Právě k tomu slouží koncept investorského sentimentu.

Baker a Wurgler (2007), navazující na De Long et al. (1990), definují investorský sentiment jako přesvědčení o budoucích peněžních tocích a investičních rizicích, které není opřeno o dostupná fakta. Nejde tedy pouze o náladu v obecném smyslu, ale o přesvědčení investorů, které se může projevovat nadměrným optimismem v obdobích euforie i přehnaným pesimismem v obdobích paniky.

Klíčová otázka však nespočívá pouze v tom, zda sentiment existuje, ale také v tom, proč racionální investoři nekorigují ceny směrem k jejich fundamentální hodnotě. De Long et al. (1990) ukazují, že i racionální investor může váhat s obchodováním proti sentimentu, protože si nemůže být jistý, že se mylné přesvědčení ostatních investorů nezačne v krátkém období projevovat ještě silněji. Jsou-li například iracionální investoři pesimističtí a tlačí cenu aktiva dolů, musí racionální investor při nákupu počítat s tím, že jejich pesimismus se může ještě prohloubit a cena dočasně klesne ještě níže. Jak ukazují De Long et al. (1990), výsledkem mohou být přetrvávající odchylky cen od fundamentálních hodnot i v prostředí bez fundamentálního rizika.

Lze tedy usoudit, že akcie jsou vůči sentimentu citlivé. Baker a Wurgler (2007) ukazují, že jde zejména o akcie malých, mladých, vysoce volatilních, či neziskových firem, případně firem nevyplácejících dividendy. U těchto společností je ocenění více subjektivní a zároveň je obtížné zaujmout opačnou pozici a sázet na návrat ceny k fundamentální hodnotě. Naopak akcie zavedených firem se stabilní ziskovostí a

pravidelnými dividendami bývají vůči sentimentu méně citlivé. Sentiment tak nelze chápat pouze jako nahodilý šum, ale jako faktor, který může systematicky ovlivňovat ceny aktiv.

2.4.1 Přehled existujících indexů sentimentu

Měření investorského sentimentu není jednotné. Různé ukazatele zachycují odlišné stránky sentimentu a liší se jak použitou metodou, tak praktickým využitím. Některé vycházejí z přímého dotazování respondentů, jiné z tržních dat a další kombinují více dílčích ukazatelů do jednoho souhrnného indexu. Pro účely této práce je důležité zejména to, zda je daný ukazatel zaměřen přímo na akciový trh, zda je veřejně dostupný a zda je aktualizován dostatečně často pro využití v obchodní strategii.

Mezi akademické ukazatele patří index Bakera a Wurglera (2006). Autoři jej sestavují ze šesti ukazatelů sentimentu, konkrétně z diskontu uzavřených fondů, obratu akcií na NYSE, počtu prvotních veřejných nabídek akcií (Initial public offering, IPO), průměrných výnosů IPO v prvním dni obchodování, podílu akciových emisí na celkových nových emisích a dividendové prémie. Z hlediska této práce je však podstatné, že jde o historicky sestavený ukazatel, nikoli o průběžně publikovaný index s denní frekvencí.

Odlišný princip představuje Volatility Index (VIX). Cboe (2019) jej zavedla v roce 1993 jako ukazatel očekávané třicetidenní volatility původně odvozené z opcí na index Standard and Poor's (S&P 100). V roce 2003 byla metodika upravena tak, aby vycházela z opcí na index Standard and Poor's 500 (S&P 500), a historická řada této novější verze je dostupná zpětně od roku 1990. VIX tak představuje průběžně publikovaný tržní ukazatel, který zachycuje očekávanou volatilitu akciového trhu.

Na jiném principu fungují ukazatele založené na přímém dotazování. Mezi ně patří Investors Intelligence Bullish Sentiment Index, který vychází z hodnocení více než 140 nezávislých investičních newsletterů. V analyzovaném souboru jsou data dostupná od roku 1964. Clarke a Statman (1998) však nezjistili statisticky významný vztah mezi hodnotami tohoto indexu a následnými výnosy indexu S&P 500. Tento ukazatel proto zachycuje náladu konkrétní skupiny komentátorů, ale jeho predikční schopnost se v dané studii nepotvrdila.

Dalším indexem je University of Michigan Index of Consumer Sentiment. Tento index vznikl v roce 1947 a na měsíční bázi je dostupný od roku 1978. Na rozdíl od předchozích ukazatelů však neměří přímo sentiment vůči akciovému trhu, ale důvěru

spotřebitelů v ekonomiku a její další vývoj. Lemmon a Portniaguina (2006) ukazují, že tento ukazatel dokáže zejména po roce 1977 předpovídat, zda budou v dalším období úspěšnější akcie menších, nebo větších firem. Tento výsledek autoři spojují s tím, že domácnosti se v pozdějším období více zapojovaly do kapitálového trhu. Pro práci zaměřenou přímo na akciový trh je však omezením tohoto ukazatele jeho širší makroekonomické zaměření.

Tab. 2.1: Srovnání vybraných nástrojů pro měření tržního sentimentu.

Index	Metodika	Frekvence	Zaměření	Data od	Volná dostupnost
Baker a Wurgler	Kompozitní (6 proměnných)	Roční (sentiment index)	Akciový trh (USA)	1962	Ano
VIX	Jednodimenzionální (volatilita opcí)	Průběžně	Akciový trh (USA)	1990	Ano
Investors Intelligence BSI	Dotazování (newslettery)	Týdenní	Akciový trh (USA)	1964	Ne
Michigan Consumer Sentiment	Dotazování domácností	Měsíční	Ekonomik a obecně	1978	Ano
CNN Fear & Greed Index	Kompozitní (7 indikátorů)	Denní	Akciový trh (USA)	2011	Ano

Zdroj: Vlastní zpracování

Z tabulky 2.1 vyplývá, že jednotlivé nástroje splňují požadovaná kritéria jen částečně. Baker a Wurgler nabízejí kompozitní ukazatel zaměřený na akciový trh, avšak bez průběžné denní aktualizace. VIX je průběžně dostupný, ale zachycuje pouze jednu dílčí stránku tržního sentimentu, konkrétně očekávanou volatilitu. Investors Intelligence Bullish Sentiment Index se vztahuje přímo k akciovému trhu, avšak není volně dostupný a jeho predikční schopnost se v uvedené studii nepotvrdila. University of Michigan Index of Consumer Sentiment je pravidelně publikovaný, ale měří spíše spotřebitelskou důvěru v ekonomiku než sentiment vůči akciovému trhu. Z porovnávaných nástrojů tak CNN Fear & Greed Index nejlépe odpovídá třem kritériím stanoveným v úvodu této podkapitoly.

2.4.2 CNN Fear & Greed Index

CNN Fear & Greed Index je ukazatel určený k posouzení toho, zda jsou aktuální pohyby na akciovém trhu ovlivněny spíše strachem, nebo chamtivostí a zda se akcie nacházejí pod tlakem nadměrného pesimismu či optimismu. FGI vychází ze sedmi tržních indikátorů a snaží se zachytit, do jaké míry emoce v daném okamžiku ovlivňují tržní

chování. CNN Business jej popisuje jako intuitivní barometr ochoty investorů podstupovat riziko na stupnici od 0 do 100, kde hodnoty blíží se nule odpovídají extrémnímu strachu, zatímco hodnoty blíží se ke stovce vyjadřují extrémní chamtivost. Index tak vyjadřuje, zda jsou tržní pohyby v danou chvíli spojeny spíše s tendencí prodávat akcie a přesouvat prostředky do bezpečnějších aktiv, nebo naopak s ochotou podstupovat vyšší riziko (CNN Business, 2026).

Myšlenka tohoto indexu vznikla v návaznosti na finanční krizi roku 2008 a na následné hledání způsobu, jak zachytit tržní náladu nad rámec běžného sledování akciových indexů. Jak uvádí Morrow (2025), index byl vytvořen zaměstnanci tehdejší redakce CNN Business jako barometr sentimentu, který měl jít dále než samotný VIX. Veřejně spuštěn byl na jaře roku 2012, avšak historická datová řada je vedena již od roku 2011. V tomto smyslu představuje kompozitní ukazatel, který se snaží postihnout celkový sentiment amerického akciového trhu prostřednictvím sedmi dílčích indikátorů (Morrow, 2025).

Sedm komponent a jejich ekonomická interpretace

CNN Fear & Greed Index je založen na sedmi dílčích indikátorech, které společně zachycují různé projevy tržního sentimentu. Nejde tedy o ukazatel postavený na jediné proměnné, ale o kompozitní index, který kombinuje informace o trendu a šíři trhu, aktivitě investorů, volatilitě, poptávce po rizikových aktivech i přesunech kapitálu mezi rizikovými a bezpečnými aktivy. Podrobnější popis konstrukce jednotlivých složek a jejich výpočtu je uveden v podkapitole 3.3.

První komponentou je Market Momentum, tedy hybnost trhu. CNN ji vztahuje k porovnání aktuální úrovně indexu S&P 500 s jeho 125denním klouzavým průměrem. Pokud se index nachází nad tímto průměrem, jde o signál pozitivní dynamiky trhu a vyšší ochoty investorů podstupovat riziko. Naopak pohyb pod touto úrovní naznačuje slábnoucí důvěru investorů a je interpretován jako signál strachu.

Druhá komponenta sleduje sílu cen akcií. Tato složka porovnává počet akcií na NYSE, které se nacházejí na 52týdenních maximech, s počtem akcií na 52týdenních minimech. Smyslem tohoto ukazatele je odlišit situaci, kdy trh roste plošně, od situace, kdy jeho výkon táhne jen úzká skupina titulů. Výrazná převaha nových maxim nad novými minimy je známkou široce rozprostřeného optimismu a index ji interpretuje jako projev chamtivosti.

Třetí komponenta měří šíři trhu prostřednictvím McClellan Volume Summation Indexu. Šíře trhu vyjadřuje, zda se na růstu nebo poklesu trhu podílí větší část akcií, nebo jen omezený počet akcií. Tento ukazatel vychází z rozdílu mezi objemem obchodů u rostoucích a klesajících akcií na burze NYSE. V rámci Fear & Greed Indexu tak zachycuje, zda je pohyb trhu podpořen širší obchodní aktivitou, nebo zda stojí jen na užší části trhu. V tomto indexu je strach chápán jako stav, kdy investoři omezují riziko a přesouvají prostředky do bezpečnějších aktiv. Chamtivost naopak označuje situaci, kdy investoři více vyhledávají riziko a jsou ochotni ve větší míře nakupovat akcie a další rizikovější aktiva. (McClellan Financial Publications, 2026)

Čtvrtou komponentou je poměr put a call opcí. CNN FGI sleduje pětidenní průměr poměru put/call. Tento ukazatel vychází z předpokladu, že vyšší poptávka po put opcích zpravidla souvisí s obavami investorů z budoucího poklesu trhu. Rostoucí poměr put opcí k call opcím je proto chápán jako projev narůstající nervozity. Hodnota nad úrovní 1 bývá považována za medvědí signál a Fear & Greed Index ji interpretuje jako indikátor strachu.

Pátá komponenta se týká tržní volatility. CNN Business v tomto případě porovnává index VIX s jeho padesátidenním klouzavým průměrem. VIX představuje očekávanou třicetidenní volatilitu odvozenou z opcí na index S&P 500 a bývá často považován za ukazatel tržní nervozity. Fear & Greed Index interpretuje rostoucí volatilitu jako signál strachu.

Šestá komponenta sleduje poptávku po bezpečných přístavech. Její logika spočívá v porovnání výnosnosti akcií a státních dluhopisů za posledních dvacet obchodních dní. Pokud v tomto období překonávají dluhopisy akcie, svědčí to o přesunu kapitálu do bezpečnějších aktiv a o rostoucí averzi investorů k riziku. Naopak vyšší výkonnost akcií naznačuje větší ochotu investorů podstupovat riziko.

Sedmou komponentou je poptávka po spekulativních dluhopisech. CNN Business ji vyjadřuje pomocí výnosového spreadu, který zachycuje, jak velkou rizikovou přírážku investoři u těchto dluhopisů požadují. Pokud investoři rizikovější dluhopisy aktivně nakupují, jejich výnosy klesají a spread se zužuje. To signalizuje vyšší toleranci k riziku a index takovou situaci vyhodnocuje jako projev chamtivosti. Naopak širší spread ukazuje na větší opatrnost investorů a posun směrem ke strachu.

Pásma indexu

CNN Business rozděluje výsledné hodnoty indexu do pěti pásem. Extrémní strach zachycují hodnoty v rozmezí 0 až 25, strach pak hodnoty od 25 do 45. Neutrální sentiment odpovídá rozmezí 45 až 55, chamtivost hodnotám od 55 do 75 a extrémní chamtivost hodnotám nad 75 (CNN Business, 2026). Extrémní pásma mohou v praxi sloužit jako signály přehnaného pesimismu nebo optimismu a v této práci představují výchozí bod pro testované obchodní strategie.

Prediktivní síla

Farrell a O'Connor (2025) ve své studii ukazují, že CNN Fear & Greed Index vykazuje prediktivní vztah k výnosům amerických akciových indexů S&P 500, Nasdaq Composite a Russell 3000. V prvním analyzovaném období 2011–2020 byl tento vztah statisticky významný u všech tří indexů, zatímco v období 2021–2024 zůstal zachován pouze u S&P 500 a Nasdaq Composite a celkově oslabil. Autoři zároveň ukazují, že v jejich testech měl Fear & Greed Index vyšší prediktivní význam než samotný VIX. Časově proměnlivá analýza navíc naznačuje, že nejsilnější byl tento vztah v první části vzorku, zejména před rokem 2014, a v pozdějších letech postupně slábl.

Omezení indexu

CNN Business sama upozorňuje, že Fear & Greed Index nepředstavuje přesný nástroj pro časování trhu, ale spíše doplňkový ukazatel, který může investorům poskytnout užitečný kontext při rozhodování. Z akademického hlediska představuje první omezení relativně krátká veřejně dostupná historická řada, která začíná až v roce 2011 a pro delší historickou analýzu je proto nedostatečná.

Významné omezení se týká transparentnosti metodiky normalizace dat. Ve veřejně dostupném popisu indexu CNN uvádí, že sleduje, jak se jednotlivé komponenty odchylují od svých průměrů vzhledem k tomu, jak obvykle kolísají, a že všech sedm složek vstupuje do výsledného skóre se stejnou vahou. Tato formulace naznačuje postup podobný z-skóre, přesný výpočet však CNN nezveřejňuje. Nejsou tak známy detailní transformační kroky ani přesný způsob převodu jednotlivých komponent na konečnou škálu od 0 do 100.

Farrell a O'Connor (2025) používají CNN Fear & Greed Index jako hotovou datovou řadu a stručně uvádějí, že je tvořen jednoduchým průměrem sedmi faktorů. Liutvinavičius et al. (2017) popisují konstrukci indikátoru sentimentu založeného na

podobné metodice jako CNN Fear & Greed Index a rovněž pracují se sedmi stejně váženými složkami. Ani jedna z těchto studií však nepřináší detailní popis normalizačního postupu ani přesný výpočetní algoritmus odpovídající interní metodice CNN. Rekonstrukce indexu pro účely této práce proto vychází z veřejně dostupné dokumentace CNN a představuje vlastní metodologickou interpretaci autora.

3 Metodologie a implementace modelu

Tato kapitola popisuje metodický postup práce od vymezení datového rámce a konstrukce rekonstruovaného Fear & Greed Indexu až po jeho validaci a následné využití v obchodních strategiích. Nejprve je představen celkový metodologický rámec, časový rozsah analýzy a datové zdroje. Na to navazuje popis normalizace a parametrizace jednotlivých komponent, konstrukce výsledného indexu, jeho validačního ověření a testování obchodních strategií. Závěrečná část kapitoly shrnuje praktickou implementaci celého modelu v jazyku Python.

3.1 Přehled metodologického rámce

V této části je nastíněn základní logický rámec empirické části práce a zároveň je podán orientační přehled navazujících metodických kroků. Nejprve je stručně popsána celková logika metodického postupu a následně časový rozsah analýzy a použité datové zdroje. Cílem této části je ukázat, jak na sebe jednotlivé kroky metodiky navazují a jakou roli plní v rekonstrukci, validaci a následném empirickém využití indexu Fear & Greed.

3.1.1 Celková logika metodického postupu

Metodika této práce je uspořádána do čtyř na sebe navazujících fází, které vedou od výběru a zpracování vstupních dat přes konstrukci rekonstruovaného Fear & Greed Indexu až k jeho validaci a následnému využití v backtestu obchodních strategií. Toto členění není pouze formální. Jednotlivé kroky na sebe věcně navazují a vytvářejí uzavřený empirický rámec, v němž by bez předchozí konstrukce a ověření indikátoru FGI nebylo možné smysluplně interpretovat výsledky obchodních strategií. Metodický postup je proto řešen tak, aby nejprve řešil samotnou rekonstrukci indexu a teprve poté jeho aplikaci v investičním kontextu.

První fáze je zaměřena na získání, zpracování a sjednocení vstupních dat a na následnou konstrukci jednotlivých komponent indexu. V tomto kroku jsou pro každou ze sedmi složek CNN Fear & Greed Indexu vybírány odpovídající datové zdroje a vhodné ukazatele, které co nejlépe odpovídají veřejně popsané metodice CNN a současně umožňují pokrýt dostatečně dlouhé historické období. Součástí této fáze je také získání dat z veřejně dostupných zdrojů a jejich úprava do podoby využitelné pro další zpracování. Vymezení časového rozsahu a použitých datových zdrojů je uvedeno v podkapitole 3.1.2. Samotný výběr a parametrizace komponent jsou následně rozpracovány v podkapitole 3.3.

Druhá fáze spočívá v převodu těchto vstupních řad na společnou interpretační škálu. Jednotlivé komponenty se totiž liší ekonomickým významem, jednotkami měření i rozsahem hodnot, a před jejich agregací je proto nutné provést normalizaci. V této fázi jsou proto testovány tři alternativní přístupy, konkrétně rolling Z-score, rolling Min-Max normalizace a rolling percentilové pořadí. Všechny metody přitom pracují s klouzavým oknem, takže každá hodnota vychází pouze z informací dostupných k danému okamžiku a není ovlivněna budoucími daty. Obecná metodika normalizace je popsána v podkapitole 3.2, zatímco konkrétní volba parametrů pro jednotlivé komponenty a výsledky grid search jsou uvedeny v podkapitole 3.3.

Třetí fáze zahrnuje konstrukci výsledného kompozitního indexu a ověření kvality jeho rekonstrukce. Na základě finálně zvolených a normalizovaných komponent jsou sestaveny dvě varianty indexu, a to FGI_Equal s rovnoměrným vážením a FGI_OLS s vahami odhadnutými pomocí regresní analýzy. Smyslem tohoto kroku není pouze vytvořit delší historickou řadu indikátoru sentimentu, ale také ověřit, nakolik rekonstruovaný index odpovídá dynamice historických hodnot CNN Fear & Greed Indexu v překrývajícím se období 2011–2026. Konstrukce obou variant je popsána v podkapitole 3.4.1 a jejich validace vůči referenčním hodnotám CNN v podkapitole 3.4.2. Teprve po tomto kroku lze rekonstruovaný index považovat za metodologicky použitelný vstup pro další empirickou analýzu.

Čtvrtá a závěrečná fáze využívá rekonstruovaný index jako vstupní signál pro obchodní strategie. Na obě varianty indexu jsou aplikovány kontrariánské, trendové a strategie založené na křížení klouzavých průměrů sentimentu. Tyto strategie jsou testovány v jednotném backtestovacím rámci, následně parametricky optimalizovány na in-sample období a poté ověřovány na samostatném out-of-sample období. Součástí této fáze je rovněž vyhodnocení výsledků pomocí souboru výkonnostních metrik a jejich porovnání s benchmarkem Buy and Hold. Klasifikace strategií, konstrukce backtestovacího rámce, parametrizace, výpočet metrik i validační schéma jsou popsány v podkapitole 3.5.

3.1.2 Časový rozsah a datové zdroje

Tato podkapitola vymezuje časový rozsah analýzy a stručně představuje datové zdroje, z nichž vychází rekonstrukce indexu, jeho validace i následný backtesting obchodních strategií.

Časové vymezení

Empirická část práce vychází z rekonstruované denní řady Fear & Greed Indexu za období 1998 až 2026. Takto vymezený horizont nebyl zvolen náhodně. Umožňuje zachytit nejen běžné tržní fáze, ale i několik výrazně odlišných tržních epizod, které jsou pro testování strategií založených na tržním sentimentu zvláště důležité, zejména korekci po splasknutí dot-com bubliny, období po teroristických útocích v září 2001, globální finanční krizi let 2008 až 2009 a propad trhu během pandemie COVID-19. Pro validaci rekonstrukce je následně využito společné období 2011 až 2026, pro které jsou k dispozici jak rekonstruované hodnoty indexu, tak historické hodnoty CNN Fear & Greed Indexu. Samotný backtesting je dále rozdělen na in-sample období od 1. 1. 1998 do 31. 12. 2015 a out-of-sample období od 1. 1. 2016 do 20. 3. 2026.

Hlavní datové zdroje

Práce využívá několik typů veřejně dostupných datových zdrojů, přičemž každý z nich plní odlišnou roli v konstrukci indexu a v následné empirické analýze. Pro cenové a tržní časové řady využité u části komponent a rovněž pro benchmarkový index S&P 500 Total Return jsou používána data z Yahoo Finance. Specializované indikátory tržní šíře a nálady na trhu opcí jsou získávány ze služby StockCharts. Údaje o výnosových spreadech vysokovýnosových dluhopisů, které vstupují do komponenty Junk Bond Demand, pocházejí z databáze FRED. Historická referenční řada CNN Fear & Greed Indexu je pak získávána z archivu portálu finhacker.cz.

Referenční řada CNN Fear & Greed Indexu

Veřejně dostupná historická řada CNN Fear & Greed Indexu začíná rokem 2011, což je pro účely robustního backtestingu krátké období. Po rozdělení na optimalizační a validační část by takový vzorek obsahoval jen omezený počet období extrémního strachu či chamtivosti, a poskytoval by tak slabší oporu pro odhad parametrů obchodních strategií. Právě proto byla v práci provedena rekonstrukce indexu zpět do roku 1998. Jako validační benchmark pro posouzení kvality této rekonstrukce je použit dataset portálu finhacker.cz, který archivuje denní hodnoty CNN Fear & Greed Indexu od 3. ledna 2011. Podle vlastní dokumentace portálu vznikl tento archiv kombinací dat z CNN Business, z archivu Wayback Machine, z veřejných repozitářů GitHub a z vlastního průběžného sběru provozovatele. Z metodologického hlediska je proto nutné tuto řadu chápat nikoli jako

interní originální dataset CNN, ale jako nejlepší veřejně dostupnou aproximaci historických hodnot indexu.

Funkce jednotlivých datasetů v analýze

V metodickém rámci práce je důležité rozlišovat mezi daty pro konstrukci indexu, daty pro jeho validaci a daty pro obchodní testování. Jednotlivé komponenty rekonstruovaného indexu jsou sestavovány z veřejně dostupných tržních řad odpovídajících sedmi složkám CNN Fear & Greed Indexu. Referenční historická řada z finhacker.cz slouží především pro validační porovnání. U varianty FGI_Equal do samotné konstrukce indexu nevstupuje, zatímco u varianty FGI_OLS je využita k odhadu regresních vah jednotlivých komponent. Samotný backtesting obchodních strategií je však v obou případech prováděn výhradně na rekonstruovaných hodnotách indexu. Benchmarkem investiční výkonnosti je strategie Buy and Hold na indexu S&P 500 Total Return.

Metodická omezení a reprodukovatelnost

Použitý postup byl navržen jako reprodukovatelné výzkumné workflow, nikoli jako průběžně aktualizovaný systém. Většina skriptů proto pracuje s pevně stanoveným koncovým datem v březnu 2026, což usnadňuje opakovatelnost výsledků. Zároveň je ale nutné počítat s několika omezeními. Ne všechny použité zdroje mají charakter oficiálně dokumentovaného API, historická řada CNN Fear & Greed Indexu není získávána přímo od CNN a část komponent je konstruována prostřednictvím veřejně dostupných zástupných ukazatelů, protože přesná interní metodika CNN nebyla zveřejněna. Detailní výběr a parametrizace těchto ukazatelů jsou proto rozpracovány v podkapitole 3.3, konstrukce a validace výsledného indexu v podkapitole 3.4 a jeho obchodní aplikace v podkapitole 3.5. Technická implementace celého výzkumného workflow v jazyce Python je následně popsána v podkapitole 3.6.

3.2 Metodika normalizace

Jednotlivé komponenty Fear & Greed Indexu jsou konstruovány z datových řad, které se vzájemně liší jak jednotkami měření, tak rozsahy hodnot. Aby bylo možné tyto heterogenní signály smysluplně agregovat do jednoho kompozitního indexu na škále 0 až 100, je nezbytné každou komponentu před agregací normalizovat. V rámci tvorby rekonstruovaného indexu byly testovány tři normalizační metody: Z-score, Min-Max normalizace a percentilové pořadí.

Všechny tři testované metody jsou implementovány výhradně ve variantě využívající klouzavé okno, přičemž normalizace v každém časovém bodě vychází pouze z dat dostupných k danému okamžiku. Použití globální normalizace, která by jako referenci využívala celou historii datové řady včetně budoucích hodnot, by zaneslo riziko look-ahead bias, tedy situace, kdy model při simulaci historického obchodování využívá informace, které v daném okamžiku ještě nebyly dostupné, a zneplatnilo by tím výsledky backtestingu.

Z-score

Z-score standardizuje hodnoty proměnné odečtením průměru a vydělením směrodatnou odchylkou, čímž zajišťuje, že měřítko původní proměnné neovlivňuje výsledek analýzy (Bruce a Bruce, 2017). V této práci je využita klouzavá varianta, kde jsou průměr μ_t (3.1) i směrodatná odchylka σ_t (3.2) počítány výhradně z pohyblivého okna délky bezprostředně předcházejících obchodních dní,

$$\mu_t = \frac{1}{w} \sum_{i=0}^{w-1} x_{t-i}, \quad (3.1)$$

$$\sigma_t = \sqrt{\frac{1}{w} \sum_{i=0}^{w-1} (x_{t-i} - \mu_t)^2}, \quad (3.2)$$

kde x_{t-i} je hodnota signálu v čase $t - i$, přičemž $i = 0$ odpovídá aktuálnímu dni a $i = w - 1$ odpovídá nejstaršímu dni v okně.

Klouzavé Z-score (3.3) je poté definováno jako:

$$z_t = \frac{x_t - \mu_t}{\sigma_t}, \quad (3.3)$$

kde x_t je hodnota signálu v čase t . Z-score tedy vyjadřuje, o kolik směrodatných odchylek se dnešní hodnota signálu odchyluje od svého klouzavého průměru.

Výsledné Z-score je následně lineárně přeškálováno na interval $\langle 0, 100 \rangle$ podle vztahu:

$$s_t = \text{clip}(z_t \cdot 25 + 50), \quad (3.4)$$

kde funkce clip ořezává hodnoty mimo interval $[0, 100]$, které mohou nastat při extrémních tržních událostech (pandas Development Team, 2024). Střed škály $s_t = 50$

odpovídá neutrálnímu stavu, kdy se signál pohybuje přesně na svém klouzavém průměru. Hodnoty $s_t < 45$ signalizují strach a hodnoty $s_t > 55$ chamtivost.

Konstanta 50 byla zvolena proto, aby neutrální hodnota $z_t = 0$ odpovídala středu škály $s_t = 50$. Koeficient 25 pak určuje šířku přeskálování tak, aby interval $\langle -2, +2 \rangle$ odpovídal škále $\langle 0, 100 \rangle$.

U komponent, kde vyšší hodnota signálu vyjadřuje strach nikoli chamtivost, je aplikována inverzní normalizace. Inverze je provedena negací Z-score (3.5) před přeskálováním:

$$s_t = \text{clip}(-z_t \cdot 25 + 50). \quad (3.5)$$

Inverzní normalizace je použita u komponent Put/Call Ratio, Market Volatility a Junk Bond Demand.

Min-Max normalizace

Klouzavá Min-Max normalizace mapuje hodnotu signálu do intervalu $\langle 0, 100 \rangle$ na základě minima a maxima pozorovaných v okně délky w bezprostředně předcházejících obchodních dní (Han et al., 2012). Klouzavé minimum (3.6) a maximum (3.7) jsou definovány jako:

$$\min_t = \min(x_{t-w+1}, \dots, x_t), \quad (3.6)$$

$$\max_t = \max(x_{t-w+1}, \dots, x_t), \quad (3.7)$$

kde $x_{t-w+1}, \dots, x_t$ jsou hodnoty signálu v okně délky w bezprostředně předcházejícím dni t . Normalizovaná hodnota je poté vypočtena dle vzorce 3.8,

$$s_t = \text{clip}\left(\frac{x_t - \min_t}{\max_t - \min_t} \cdot 100\right), \quad (3.8)$$

kde x_t je hodnota signálu v čase t , $\min_t$ a $\max_t$ jsou klouzavé minimum a maximum ze stejného okna a funkce *clip* ořezává hodnoty na interval $\langle 0, 100 \rangle$ (pandas Development Team, 2024). Násobením 100 je výsledek přeskálován z intervalu $\langle 0, 1 \rangle$ na interval $\langle 0, 100 \rangle$, shodný se škálou ostatních komponent indexu.

U komponent, kde vyšší hodnota surového signálu vyjadřuje strach, je aplikována inverzní varianta a to dle vzorce:

$$s_t = \text{clip} \left(\frac{\max_t - x_t}{\max_t - \min_t} \cdot 100 \right). \quad (3.9)$$

Nevýhodou min-max metody je citlivost na extrémní hodnoty. Jediný výjimečný výkyv v okně posune $\max_t$ nebo $\min_t$ a zkomprimuje všechny ostatní hodnoty do úzkého pásma.

Percentilové pořadí

Percentilové pořadí vyjadřuje relativní postavení hodnoty signálu vůči ostatním hodnotám v okně s délkou trvání w . Percentilové pořadí udává, kolik procent historických hodnot je nižších než aktuální hodnota signálu. (Roscoe, 1975). Klouzavé percentilové pořadí (3.10) je definováno jako:

$$s_t = \frac{\sum_{j=t-w+1}^{t-1} \mathbf{1}(x_j < x_t)}{w-1} \cdot 100, \quad (3.10)$$

kde $\mathbf{1}(x_j < x_t)$ je funkce nabývající hodnoty 1 pokud $x_j < x_t$ a 0 v opačném případě, x_j jsou hodnoty signálu v okně w dní předcházejících dni t a $w-1$ je počet historických hodnot v okně. Výsledná hodnota $s_t \in \langle 0, 100 \rangle$ udává, kolik procent hodnot v okně bylo nižších než x_t . Čím vyšší hodnota, tím více signál převyšuje své historické hodnoty v okně.

Na rozdíl od Min-Max normalizace je percentilové pořadí robustní vůči extrémním hodnotám, protože výsledná hodnota závisí pouze na pořadí hodnot v okně, nikoli na jejich absolutní velikosti. U komponent, u nichž vyšší hodnota surového signálu indikuje strach, je použita inverzní varianta podle vztahu:

$$s_t = 100 - s_t. \quad (3.11)$$

Zdůvodnění volby finální normalizační metody

Jako finální normalizační metoda byla zvolena varianta rolling Z-score. Toto rozhodnutí vychází z veřejně dostupného popisu CNN, podle nějž index sleduje odchylku jednotlivých indikátorů od jejich průměrů vzhledem k tomu, jak obvykle kolísají (CNN Business, 2026), což je nejvíce konzistentní s principem Z-score (Bruce a Bruce, 2017). Min-Max normalizace a percentilové pořadí byly do grid search zahrnuty pouze za účelem empirického ověření této volby. Protože CNN nezveřejňuje přesnou délku použitého okna, byla u každé komponenty testována sada dvanácti oken od 21 do 1512

obchodních dní. U některých komponent byly současně testovány i alternativní formulace vstupního signálu a alternativní instrumenty. Konkrétní rozsah grid search a výsledná volba parametrů jsou uvedeny v následující podkapitole 3.3 u jednotlivých komponent.

3.3 Výběr a parametrizace komponent indexu

Výběr parametrů každé komponenty se řídil dvěma kritérii. Primárním kritériem byla konzistence s metodikou CNN, která pro jednotlivé komponenty popisuje zdrojové indikátory a v některých případech i způsob jejich výpočtu. Sekundárním kritériem byla maximalizace Pearsonova korelačního koeficientu mezi normalizovanou komponentou a referenčními hodnotami CNN FGI za období 2011–2026. Pearsonův korelační koeficient je definován jako průměr součinů standardizovaných hodnot dvou proměnných a vyjadřuje sílu a směr jejich lineárního vztahu (Roscoe, 1975).

3.3.1 První komponenta - Market Momentum

Komponenta Market Momentum měří, zda se S&P 500 obchoduje nad nebo pod svým 125denním klouzavým průměrem. CNN popisuje tuto komponentu jako "S&P 500 and its 125-day moving average", přičemž přesný vzorec výpočtu není publikován. Signál je v této práci definován jako absolutní rozdíl indexu od jeho 125denního klouzavého průměru,

$$m_t = SP500_t - MA_t, \quad (3.12)$$

kde $SP500_t$ je hodnota indexu S&P 500 v čase t a MA_t je 125denní klouzavý průměr indexu S&P 500. Kladné hodnoty m_t signalizují, že index se obchoduje nad svým střednědobým průměrem a indikují chamtivost, záporné hodnoty naopak indikují strach.

V rámci grid search bylo testováno celkem 72 kombinací parametrů, konkrétně 2 typy signálu (absolutní rozdíl a procentuální odchylka), 3 normalizační metody a 12 normalizačních oken při fixním MA125 dle metodiky CNN. Nejvyšší korelace dosáhla kombinace absolutního rozdílu se Z-score normalizací a oknem 63 obchodních dní, s korelací $r = 0,832$.

3.3.2 Druhá komponenta - Stock Price Strength

Komponenta Stock Price Strength měří sílu trhu prostřednictvím poměru počtu akcií NYSE dosahujících 52týdenních maxim vůči počtu akcií dosahujících 52týdenních minim. CNN tuto komponentu popisuje jako „Net new 52-week highs and lows on the NYSE“. Signál je definován jako normalizovaný poměr,

$$p_t = \frac{NYHGH_t - NYLOW_t}{NYHGH_t + NYLOW_t}, \quad (3.13)$$

kde $NYHGH_t$ je počet akcií na burze NYSE dosahujících 52týdenního maxima v čase t a $NYLOW_t$ je počet akcií dosahujících 52týdenního minima. Hodnoty blízké 1 indikují chamtivost, hodnoty blízké -1 strach. Pro odstranění denního šumu je poměr vyhlazován 5denním klouzavým průměrem.

V rámci grid search bylo testováno 10 formulací signálu, mimo jiné absolutní rozdíl $NYHGH - NYLOW$, podíl $NYHGH_t / (NYHGH_t + NYLOW_t)$, logaritmický poměr $\log(NYHGH_t / NYLOW_t)$ a jejich varianty vyhlazené klouzavými průměry 5 a 20 dní. Celkem bylo vyhodnoceno 360 kombinací parametrů. Nejvyšší korelace s referenčními hodnotami CNN FGI dosáhla kombinace poměru vyhlazovaného 20denním klouzavým průměrem s percentilovým pořadím ($r = 0,761$), nicméně z důvodu metodologické konzistence byla zvolena Z-score normalizace. V rámci Z-score variant dosáhla nejvyšší korelace kombinace poměru vyhlazovaného 5denním klouzavým průměrem s normalizačním oknem 504 obchodních dní. Korelace výsledné normalizované komponenty s CNN FGI činí $r = 0,758$.

3.3.3 Třetí komponenta - Stock Price Breadth

Komponenta Stock Price Breadth měří šíři trhu prostřednictvím NYSE Volume McClellan Summation Index (VMCSUMNYA), který redakce CNN uvádí přímo jako zdrojový indikátor pro tuto komponentu. Jedná se o kumulativní indikátor tržní šíře odvozený z objemu rostoucích a klesajících akcií na NYSE. Data pro tuto komponentu jsou získávána ze služby StockCharts, přičemž technický způsob jejich stažení je popsán v podkapitole 3.6.2.

Vstupní signál je tvořen přímo hodnotami z indexu NYSE Volume McClellan Summation Index bez dalších úprav. Kladné hodnoty indikují převahu rostoucích objemů a signalizují chamtivost, záporné hodnoty naopak strach.

V rámci grid search bylo testováno celkem 36 kombinací parametrů, konkrétně 3 normalizační metody a 12 normalizačních oken. Nejvyšší korelace s referenčními hodnotami CNN FGI dosáhla varianta rolling Z-score s oknem 126 obchodních dní ($r = 0,816$). Tato hodnota byla vyšší než nejlepší výsledky dosažené pomocí percentilového pořadí ($r = 0,808$) a Min-Max normalizace ($r = 0,801$).

3.3.4 Čtvrtá komponenta - Put/Call Ratio

Komponenta Put/Call Ratio měří sentiment na trhu opcí prostřednictvím poměru objemu put opcí vůči call opcím. CNN tuto komponentu popisuje jako "5-day average put/call ratio". Vysoký poměr signalizuje převahu put opcí, tedy zajišťovací nebo spekulativní pozice na pokles, a tím i strach. Nízký poměr naopak indikuje chamtivost. Komponenta využívá inverzní normalizaci.

Jako zdrojový indikátor byl zvolen CBOE Total Put/Call Ratio (CPC), který zahrnuje jak akciové, tak indexové opce a je dostupný od roku 1995. Alternativní indikátory CBOE Equity-Only Put/Call Ratio (CPCE) a CBOE Index-Only Put/Call Ratio (CPCI) nebyly do grid search zařazeny, neboť jsou dostupné pouze od roku 2003 a nepokrývají krizové období dot-com bubliny 2000-2002, které je klíčové pro rekonstrukci indexu. Signál je tvořen 5denním klouzavým průměrem CPC, v souladu s metodikou CNN.

V rámci grid search bylo testováno celkem 180 kombinací parametrů, konkrétně 5 oken klouzavého průměru, 3 normalizační metody a 12 normalizačních oken. Nejvyšší korelace s referenčními hodnotami CNN FGI dosáhla kombinace 10denního klouzavého průměru se Z-score normalizací a oknem 126 dní ($r = 0,667$). Z důvodu metodologické konzistence s metodikou CNN, která explicitně uvádí 5denní průměr, byl však zvolen 5denní klouzavý průměr se Z-score normalizací a oknem 252 obchodních dní, s korelací $r = 0,643$.

3.3.5 Pátá komponenta - Market Volatility

Komponenta Market Volatility měří úroveň tržní volatility prostřednictvím indexu VIX. CNN tuto komponentu popisuje jako "VIX and its 50-day moving average", přičemž vysoká volatilita signalizuje strach a nízká volatilita chamtivost. Komponenta proto využívá inverzní normalizaci. Signál je definován jako poměr:

$$v_t = \frac{VIX_t}{MA_t}, \quad (3.14)$$

kde VIX_t je denní hodnota indexu VIX v čase t a MA_t je jeho 50denní klouzavý průměr. Hodnoty nad 1 signalizují, že aktuální volatilita trhu převyšuje svůj střednědobý průměr, což investoři obvykle vnímají jako signál nejistoty a strachu. Hodnoty pod 1 naopak indikují klidné tržní prostředí a chamtivost.

V rámci grid search bylo testováno celkem 432 kombinací parametrů. Testovány byly čtyři typy signálu: absolutní hodnota VIX, poměr VIX k MA pro okna 20, 50, 125 a 252 dní, absolutní rozdíl VIX od MA pro stejná okna a procentuální změna VIX za 5, 10 a 20 dní. Celkem 12 variant bylo kombinováno se 3 normalizačními metodami a 12 normalizačními okny. Nejvyšší korelace dosáhla absolutní hodnota VIX ($r = 0,712$), nicméně z důvodu metodologické konzistence s CNN, která explicitně uvádí porovnání VIX s jeho 50denním klouzavým průměrem, byl zachován poměr VIX_t/MA_t . Signál je normalizován metodou rolling Z-score s oknem 1512 obchodních dní. Korelace výsledné normalizované komponenty s CNN FGI činí $r = 0,646$.

3.3.6 Šestá komponenta - Safe Haven Demand

Komponenta Safe Haven Demand měří, zda investoři preferují bezpečná aktiva před rizikovými. CNN tuto komponentu popisuje jako "Difference in 20-day stock and bond returns" a uvádí, že dluhopisy si vedou lépe ve chvílích, kdy jsou investoři vystrašení. Signál je definován jako rozdíl 20denních výnosů akciového indexu a dluhopisového fondu,

$$h_t = r_t^{akcie} - r_t^{dluhopisy}, \quad (3.15)$$

kde r_t^{akcie} je 20denní procentuální výnos akciového indexu a $r_t^{dluhopisy}$ je 20denní procentuální výnos dluhopisového fondu. Kladné hodnoty signalizují, že akcie překonávají dluhopisy a indikují chamtivost. Záporné hodnoty naopak signalizují útek investorů do bezpečných aktiv a indikují strach. Komponenta tedy nevyužívá inverzní normalizaci.

V rámci grid search bylo testováno celkem 900 kombinací parametrů, konkrétně 5 akciových indexů: S&P 500, Dow Jones Industrial Average, NASDAQ Composite, NYSE Composite Index a Russell 2000 Index, a 5 dluhopisových fondů: Vanguard Long-Term Treasury Fund, Vanguard Intermediate-Term Treasury Fund, Vanguard Short-Term Treasury Fund, Vanguard Total Bond Market Index Fund a Vanguard Long-Term Investment-Grade Fund, 3 normalizační metody a 12 normalizačních oken. Nejlepší kombinace celkově dosáhla kombinace S&P 500 s Vanguard Treasury 1-3 yr s percentilovým pořadím ($r = 0,770$). Z důvodu metodologické konzistence se Z-score normalizací byla zvolena kombinace NASDAQ Composite s Vanguard Treasury 5-10 yr se Z-score normalizací ($r = 0,730$) a oknem 504 obchodních dní.

3.3.7 Sedmá komponenta - Junk Bond Demand

Komponenta Junk Bond Demand měří ochotu investorů podstupovat kreditní riziko. CNN tuto komponentu popisuje jako "Yield spread: junk bonds vs. investment grade" a uvádí, že užší spread signalizuje chamtivost, širší strach. Komponenta využívá inverzní normalizaci.

Jako signál byl zvolen ICE BofA US High Yield Index Option-Adjusted Spread (BAMLH0A0HYM2) dostupný z databáze FRED od roku 1996. Tento spread měří rozdíl výnosů amerických vysokovýnosových dluhopisů vůči spotové křivce státních dluhopisů USA (Treasury curve). Ze všech testovaných variant dosáhl BAMLH0A0HYM2 nejvyšší korelace a zároveň pokrývá celé rekonstruované období od roku 1996.

V rámci grid search bylo testováno celkem 468 kombinací parametrů ze 13 variant signálu, 3 normalizačních metod a 12 normalizačních oken. Testovány byly tři skupiny signálů: přímé OAS spready z FRED (BAMLH0A0HYM2, BAMLH0A1HYBB, BAMLC0A4CBBB, BAMLC0A3CA), diferenciály mezi junk a investment grade OAS spready a rozdíly 20denních výnosů ETF párů (HYG, JNK, VWEHX vůči LQD, VWESX a VBMFX). Nejlepšího výsledku dosáhl přímý spread BAMLH0A0HYM2 se Z-score normalizací a oknem 63 obchodních dní, s korelací $r = 0,768$.

3.4 Konstrukce kompozitního Fear & Greed Indexu

Rekonstruovaný Fear & Greed Index je konstruován ve dvou variantách lišících se způsobem vážení normalizovaných komponent. Normalizace každé komponenty metodou klouzavého Z-score je popsána v podkapitole 3.2 (vzorec 3.3), výběr a parametrizace jednotlivých komponent včetně výsledků grid search jsou popsány v

předcházející podkapitole 3.3. Výsledný index pokrývá období 1998–2026 (7 097 obchodních dní), čímž oproti původním datům CNN dostupným od roku 2011 rozšiřuje časový horizont o přibližně třináct let a zahrnuje krizové epizody dot-com bubliny, teroristických útoků v září 2001 a finanční krize 2008–2009.

3.4.1 Váhové schéma a agregace

Primární varianta FGI_Equal implementuje metodiku CNN, která uvádí, že index přiřazuje každému ze sedmi indikátorů stejnou váhu při výpočtu skóre v rozsahu 0 až 100 (CNN Business, 2026). Výsledná hodnota indexu je proto aritmetickým průměrem sedmi normalizovaných komponent a je dána vztahem:

$$FGI_Equal_t = \frac{1}{7} \sum_{i=1}^7 z_{i,t}, \quad (3.16)$$

kde $z_{i,t}$ je normalizovaná hodnota i – té komponenty v čase t .

Doplňková varianta FGI_OLS odvozuje váhy komponent regresní analýzou metodou nejmenších čtverců. V regresním modelu jsou normalizované hodnoty sedmi komponent vysvětlujícími proměnnými a archivované denní hodnoty CNN Fear & Greed Indexu závislou proměnnou. Metoda nejmenších čtverců odhaduje koeficienty modelu tak, aby součet čtverců odchylek mezi pozorovanými a předpovězenými hodnotami byl minimální (McClave et al., 2017). Výsledná hodnota FGI_OLS je dána vztahem 3.17

$$FGI_OLS_t = \beta_0 + \sum_{i=1}^7 \beta_i \cdot z_{i,t}, \quad (3.17)$$

kde $z_{i,t}$ je normalizovaná hodnota i – té komponenty v čase t vypočtená dle vzorce (3.3), β_i jsou odhadnuté koeficienty jednotlivých komponent, tedy jejich výsledné váhy v indexu a β_0 je absolutní člen představující odhadnutou hodnotu indexu v případě, kdy jsou všechny normalizované komponenty nulové. Tato varianta je konstruována jako metodologické ověření, zda empiricky odvozené váhy dosahují lepší shody s referenčními hodnotami CNN než rovnoměrné vážení.

Tab. 3.1 Váhy komponent FGI_Equal a FGI_OLS

Komponenta	FGI_Equal	FGI_OLS
Market Momentum	0,1429	0,1885
Stock Price Strength	0,1429	0,1041
Stock Price Breadth	0,1429	0,2378
Put/Call Ratio	0,1429	0,0576
Market Volatility	0,1429	0,0120
Safe Haven Demand	0,1429	0,1510
Junk Bond Demand	0,1429	0,1062
Absolutní člen	—	5,5141

Zdroj: Vlastní zpracování

Z tabulky 3.1 je patrné, že metoda nejmenších čtverců (OLS) přiřadila jednotlivým komponentám rozdílné váhy, a odchýlilo se tak od rovnoměrného schématu varianty FGI_Equal. Nejvyšší váhu získala komponenta Stock Price Breadth (0,2378), což naznačuje, že právě ukazatel tržní šíře nesl ve společném období největší podíl informace potřebné k vysvětlení pohybu referenčního CNN Fear & Greed Indexu. Tato komponenta zachycuje, zda je vývoj trhu podpořen širší obchodní aktivitou, nebo zda stojí pouze na užší části titulů, a v tomto smyslu může představovat stabilnější signál celkové tržní nálady. Významnou váhu získaly také komponenty Market Momentum (0,1885) a Safe Haven Demand (0,1510), tedy indikátory zachycující jak směr trhu, tak přesuny kapitálu mezi rizikovými a bezpečnými aktivy.

Nejnižší váhu naopak získala komponenta Market Volatility (0,0120), jejíž koeficient jako jediný není statisticky významný ($p = 0,174$). Možným vysvětlením je, že informace nesená indexem VIX se v regresním modelu do určité míry překrývá s informací obsaženou v komponentě Market Momentum. V obdobích poklesu trhu se totiž VIX zpravidla zvyšuje, zatímco index S&P 500 se současně vzdaluje směrem dolů od svého klouzavého průměru.

3.4.2 Validace rekonstrukce

Kvalita rekonstrukce byla hodnocena na překrývajícím se období 2011–2026, pro které jsou z portálu finhacker.cz dostupné archivované denní hodnoty CNN Fear & Greed Indexu. Tyto hodnoty slouží v práci jako referenční benchmark pro posouzení shody rekonstruovaného indexu s původním CNN indexem. V případě varianty FGI_Equal nebyly použity jako vstup do konstrukce indexu a slouží výhradně k validačnímu srovnání. U varianty FGI_OLS byly naopak využity k odhadu regresních vah

jednotlivých komponent, a výsledky této varianty je proto třeba interpretovat jako kalibrovanou rekonstrukci vůči referenčnímu indexu, nikoli jako plně nezávislou validaci.

Pro kvantifikaci shody rekonstrukce s referenčními hodnotami CNN byly použity následující metriky. Pearsonův korelační koeficient vyjadřuje sílu a směr lineárního vztahu mezi rekonstrukcí a referenční řadou CNN. Střední absolutní chyba (MAE) je definována vztahem:

$$MAE = \frac{1}{n} \sum_{t=1}^n |\hat{y}_t - y_t|, \quad (3.18)$$

kde $\hat{y}_t$ je rekonstruovaná hodnota indexu a y_t referenční hodnota CNN v čase t . MAE vyjadřuje průměrnou velikost chyby v bodech škály 0 až 100 a představuje přirozenou míru průměrné chyby modelu, neboť přímo odráží průměr absolutních odchylek bez dalších transformací (Willmott a Matsuura, 2005).

Mean Bias Error (MBE), je definován jako:

$$MBE = \frac{1}{n} \sum_{t=1}^n (\hat{y}_t - y_t), \quad (3.19)$$

kde $\hat{y}_t$ je rekonstruovaná hodnota indexu a y_t je referenční hodnota CNN v čase t (Willmott a Matsuura, 2005). Kladná hodnota indikuje systematické nadhodnocení, záporná hodnota systematické podhodnocení rekonstrukce vůči CNN.

Zatímco MAE zachycuje průměrnou velikost chyby bez ohledu na její směr, MBE zachovává znaménko a odhaluje nadhodnocení nebo podhodnocení rekonstrukce vůči referenčním hodnotám CNN.

Koeficient determinace R^2 je definován vztahem:

$$R^2 = 1 - \frac{SSE}{SS_{yy}}, \quad (3.20)$$

kde SSE představuje součet čtverců reziduí a SS_{yy} celkový součet čtverců odchylek referenčních hodnot CNN od jejich průměru. Koeficient determinace R^2 tak vyjadřuje podíl celkové variability referenčních hodnot CNN vysvětlený rekonstruovanou variantou. (McClave et al., 2017).


Devadesátý percentil absolutní chyby (P90) udává hranici, pod níž leží 90 % pozorovaných absolutních odchylek. Zachycuje tedy chování modelu v oblasti větších chyb.

Tab. 3.2 Metriky validace rekonstrukce Fear & Greed Indexu (2011–2026)

Metrika	FGI_Equal	FGI_OLS
Pearson r	0,925	0,940
R ²	0,838	0,883
MAE (body)	6,79	5,75
MBE (body)	+2,11	−0,01
P90 absolutní chyba (body)	13,9	11,8

Zdroj: Vlastní zpracování

Primární varianta FGI_Equal dosahuje korelace 0,925 s referenčními hodnotami CNN a MAE 6,79 bodu. Doplnková varianta FGI_OLS dosahuje ve všech metrikách mírně vyšší přesnosti, přičemž téměř nulová hodnota MBE (−0,01) je přirozeným důsledkem toho, že OLS minimalizuje součet čtverců odchylek mezi pozorovanými a předpovězenými hodnotami (McClave et al., 2017). Úplné srovnání obou variant napříč všemi metrikami uvádí tabulka 3.2. Dosažená shoda obou variant odráží skutečnost, že přesná normalizační okna a interní váhy CNN nejsou veřejně dostupné; rekonstrukce proto nepředstavuje přesnou reprodukci, nýbrž aproximaci.



Graf 3.1 Časové srovnání rekonstruovaných variant FGI_Equal a FGI_OLS s referenčním CNN Fear & Greed Indexem (2011–2026)


Zdroj: Vlastní zpracování

Na grafu 3.1 je znázorněna časová řada obou rekonstruovaných variant FGI_Equal a FGI_OLS spolu s referenčními hodnotami CNN Fear & Greed Indexu v

období 2011–2026. Graf 3.1 umožňuje vizuálně posoudit, nakolik rekonstrukce sleduje dynamiku skutečného CNN indexu včetně krizových epizod a období extrémního sentimentu.

Grafy 3.2 a 3.3 znázorňují průměrnou hodnotu MBE zvlášť pro každé z pěti pásem CNN indexu (Extreme Fear 0–25, Fear 25–45, Neutral 45–55, Greed 55–75, Extreme Greed 75–100) pro varianty FGI_Equal a FGI_OLS. Zatímco souhrnné metriky v tabulce 3.2 zachycují průměrnou chybu přes celé období, tyto grafy odhalují strukturu zkreslení v závislosti na úrovni sentimentu.


Na grafu 3.2 lze pozorovat, že FGI_Equal vykazuje kladný MBE ve čtyřech pásmech z pěti, přičemž nejvýraznější nadhodnocení se projevuje v pásmech Fear (+4,4 bodu) a Neutral (+4,3 bodu). Jediné pásmo se záporným MBE je Extreme Greed (–5,1 bodu), kde FGI_Equal naopak podhodnocuje referenční hodnoty CNN. Záporný MBE v tomto pásmu je konzistentní s empiricky pozorovaným maximem FGI_Equal 90,2 bodu oproti maximu CNN 97,0 bodu, tedy rekonstrukce nedosahuje nejvyšších hodnot CNN indexu.



Graf 3.2 Průměrná hodnota MBE podle pásem CNN Fear & Greed Indexu pro variantu FGI_Equal

Zdroj: Vlastní zpracování

Na grafu 3.3 lze pozorovat, že FGI_OLS vykazuje výrazně rovnoměrnější rozložení MBE napříč pásmy, s mírnými kladnými hodnotami v pásmech Extreme Fear (+2,0), Fear (+2,0) a Neutral (+1,2) a mírným záporným MBE v pásmu Greed (–0,8). Výjimkou zůstává pásmo Extreme Greed, kde FGI_OLS podhodnocuje o –8,1 bodu.



Graf 3.3 Průměrná hodnota MBE podle pásem CNN Fear & Greed Indexu pro variantu FGI_OLS

Zdroj: Vlastní zpracování

3.5 Obchodní strategie založené na rekonstruovaném FGI

Tato kapitola popisuje způsob, jakým jsou rekonstruované varianty FGI využity jako vstupní signál pro obchodní strategie. Nejprve je představena klasifikace a logika testovaných strategií, poté jednotný rámec backtestingu a jejich formální matematické vymezení. Následně jsou popsány parametry použitých strategií, postup grid search, soubor výkonnostních metrik a nakonec i validační schéma včetně srovnání s benchmarkem Buy and Hold.

3.5.1 Klasifikace a přehled testovaných strategií

Na rekonstruovaném Fear & Greed Indexu byly v této práci testovány dvě varianty vstupního signálu, konkrétně FGI_Equal a FGI_OLS. Varianta FGI_Equal představuje základní metodologickou verzi indexu, v níž mají všechny komponenty stejnou váhu. Naproti tomu FGI_OLS využívá váhy odhadnuté pomocí regresní analýzy vůči referenčním hodnotám CNN Fear & Greed Indexu. Tvorba obou variant indexu je blíže popsána v podkapitole 3.4. Všechny strategie byly aplikovány stejným způsobem na obě varianty rekonstruovaného indexu, přičemž rozdíl mezi FGI_Equal a FGI_OLS spočívá pouze v konstrukci vstupního signálu.

Testované strategie lze rozdělit podle dvou hledisek. Prvním z nich je logika interpretace sentimentu. Kontrariánské strategie vycházejí z předpokladu, že extrémní hodnoty sentimentu bývají spojeny s přehnanou reakcí trhu a mohou předcházet obratu. Nízké hodnoty indexu proto interpretují jako příležitost k otevření dlouhé pozice, zatímco

vysoké hodnoty jako signál k uzavření pozice nebo k otevření krátké pozice. Trendové strategie naopak předpokládají, že sentiment může po určitou dobu přetrvávat. Tato klasifikace navazuje na teoretická východiska behaviorálních financí a tržního sentimentu popsaná v podkapitolách 2.3 a 2.4.

Druhým hlediskem je rozsah povolených pozic. Long-only strategie připouští pouze dlouhou pozici nebo setrvání v hotovosti. Kombinované strategie vedle toho umožňují i krátkou pozici. Kromě úrovnových strategií založených na překročení pevně stanovených prahů rekonstruovaného indexu FGI byly do testu zařazeny také dvě strategie využívající křížení klouzavých průměrů sentimentu. Ty nesledují absolutní úroveň indexu, ale změnu jeho trendu.

Celkem bylo testováno šest strategií: `kontrarian_long`, `kontrarian_combined`, `trend_long`, `trend_combined`, `ma_long` a `ma_combined`. První čtyři strategie spadají do skupiny úrovnových strategií, protože obchodní pravidla odvozují přímo od předem definovaných prahových hodnot indexu. Poslední dvě strategie jsou založeny na křížení klouzavých průměrů indexu sentimentu, konkrétně na vztahu mezi jeho rychlým a pomalým klouzavým průměrem. Všechny strategie byly aplikovány jak na variantu `FGI_Equal`, tak na variantu `FGI_OLS`. Tabulka 3.3 shrnuje základní klasifikaci testovaných strategií, jejich obchodní logiku, povolené pozice a optimalizované parametry.

Ve všech testovaných obchodních strategiích je obchodovaným aktivem index S&P 500 Total Return. Rekonstruovaný FGI slouží pouze jako signál pro nákup, prodej nebo uzavření pozice.

Z hlediska konstrukce experimentu je důležité zdůraznit, že kontrariánské a trendové strategie nepředstavují pouze dvě technicky odlišné varianty téhož pravidla, ale dva odlišné teoretické přístupy k interpretaci sentimentu. Kontrariánský přístup vychází z předpokladu, že extrémní strach i extrémní chamtivost mohou signalizovat přehnanou reakci trhu, po níž následuje návrat cen k rovnovážnějším úrovním. Trendový přístup naopak vychází z předpokladu, že převládající tržní sentiment může určitou dobu přetrvávat a být spojen s pokračováním dosavadního směru trhu. Zařazení obou přístupů do jedné testovací sady tak umožňuje empiricky ověřit, zda rekonstruovaný Fear & Greed Index lépe funguje jako signál mean reversion, nebo jako signál trendového pokračování. Tato komparace je dále doplněna o rozlišení mezi long-only a combined variantami. Díky

tomu lze posoudit, zda je sentiment využitelný hlavně pro načasování vstupu do dlouhé pozice, nebo také pro krátké pozice.

Tabulka 3.3: Přehled testovaných obchodních strategií založených na rekonstruovaném FGI. Zdroj: vlastní zpracování podle implementace strategií.

Strategie	Typ logiky	Povolené pozice	Obchodní pravidlo	Parametry
kontrarian_long	kontrariánská, úrovněová	LONG, CASH	při nízké hodnotě FGI otevírá dlouhou pozici, při vysoké hodnotě FGI ji uzavírá do cash	entry, exit
kontrarian_combined	kontrariánská, úrovněová	LONG, SHORT, CASH	při nízké hodnotě FGI otevírá dlouhou pozici, při vysoké hodnotě FGI otevírá krátkou pozici	entry, exit
trend_long	trendová, úrovněová	LONG, CASH	při vysoké hodnotě FGI otevírá dlouhou pozici, při poklesu sentimentu pod výstupní práh přechází do cash	entry, exit
trend_combined	trendová, úrovněová	LONG, SHORT, CASH	při vysoké hodnotě FGI otevírá dlouhou pozici, při nízké hodnotě FGI otevírá krátkou pozici	entry, exit
ma_long	trendová, MA crossover	LONG, CASH	drží dlouhou pozici, pokud je rychlý klouzavý průměr FGI nad pomalým, jinak drží cash	fast, slow
ma_combined	trendová, MA crossover	LONG, SHORT, CASH	drží dlouhou pozici, pokud je rychlý klouzavý průměr FGI nad pomalým, a krátkou pozici v opačném případě	fast, slow

Zdroj: Vlastní zpracování

Obě strategie založené na křížení klouzavých průměrů lze v tomto rámci chápat jako strategie trendové. Nepracují totiž s návratem sentimentu od extrémních úrovní, ale s předpokladem, že převaha krátkodobého vývoje sentimentu nad jeho dlouhodobější složkou může signalizovat pokračování aktuálního režimu. Strategie ma_long tuto logiku využívá pouze pro rozhodnutí mezi dlouhou pozicí a hotovostí, zatímco ma_combined ji rozšiřuje i o možnost syntetické krátké pozice.

3.5.2 Jednotný rámec backtestingu a simulace obchodování

Všechny testované strategie byly vyhodnoceny v jednotném backtestovacím rámci, aby byly jejich výsledky vzájemně přímo srovnatelné. Simulace pracuje s počátečním kapitálem 10 000 USD a je vedena v denní frekvenci. Portfolio se může nacházet ve třech základních stavech, a to LONG, CASH a SHORT, přičemž konkrétní strategie využívají buď pouze podmnožinu těchto stavů, nebo všechny tři. Tímto sjednocením se eliminuje situace, kdy by rozdíly ve výkonnosti byly způsobeny odlišnou technikou simulace namísto samotné logiky obchodních pravidel.

Jádrem celého systému je model simulace podle držené pozice, v němž se hodnota portfolia v každém kroku aktualizuje podle toho, zda strategie mezi dvěma po sobě jdoucími dny drží pozici LONG, CASH nebo SHORT. Pokud je portfolio v dlouhé pozici, jeho hodnota se vyvíjí ve stejném směru jako cena podkladového aktiva. Ve stavu CASH zůstává beze změny. Krátká pozice je naopak modelována inverzně, takže pokles ceny indexu vede k růstu hodnoty portfolia a růst ceny k jejímu poklesu. Tento mechanismus je dán vztahem:

$$E_{t+1} = \begin{cases} E_t(1 + r_t), & \text{je-li } p_t = LONG, \\ E_t, & \text{je-li } p_t = CASH, \\ E_t(1 - r_t), & \text{je-li } p_t = SHORT, \end{cases} \quad (3.21)$$

kde E_t označuje hodnotu portfolia v čase t , p_t drženou pozici a r_t denní výnos podkladového aktiva mezi dny t a $t + 1$.

Z hlediska časování obchodních signálů je podstatné, že model nejprve započte výnos z již otevřené pozice a teprve následně na základě aktuální hodnoty indikátoru FGI určí, zda má být pozice změněna. Jinými slovy, signál pozorovaný v čase t neovlivňuje právě vyhodnocovaný interval mezi t a $t + 1$, ale až následující obchodní krok. Tato konstrukce zavádí jednodenní zpoždění mezi vznikem signálu a jeho promítnutím do portfolia a současně brání tomu, aby strategie pracovala s informací ze stejného dne při vyhodnocení výnosu, který už byl realizován (Kresta, 2024).

Nezbytnou součástí simulace jsou transakční náklady (Kresta, 2024). Ty jsou ve všech strategiích stanoveny jednotně na úrovni 0,1 % za jednu změnu pozice. Přejed z CASH do LONG nebo z LONG do CASH proto znamená jeden poplatek, zatímco přímý přechod z LONG do SHORT, případně opačně, je interpretován jako uzavření jedné pozice a současné otevření druhé, a zatěžuje tedy portfolio dvěma poplatky. Po započtení nákladů lze hodnotu portfolio vyjádřit vztahem:

$$E_{t+1}^{net} = E_{t+1}^{gross} (1 - c)^{k_t}, \quad (3.22)$$

kde c představuje sazbu transakčního nákladu a k_t počet účtovaných poplatkových jednotek v daném kroku. Tento mechanismus má praktický dopad zejména u aktivnějších strategií, u nichž častější změny pozice snižují jejich výkonnost.

Model současně předpokládá, že na konci testovaného období nezůstává žádná otevřená pozice. Pokud je portfolio v posledním dni stále v režimu LONG nebo SHORT, je tato pozice uzavřena za cenu dodatečného transakčního nákladu. Výsledná equity křivka tak vždy odpovídá plně uzavřenému investičnímu cyklu. Kód navíc obsahuje ochranný mechanismus pro případ, že by hodnota portfolio vlivem extrémně nepříznivého vývoje klesla na nulu; v takové situaci se simulace ukončí a zbývající část equity křivky zůstane nulová.

Krátká pozice je v celém systému modelována zjednodušeně tak, že se hodnota portfolio v daném dni vyvíjí opačně než denní výnos indexu. Simulace tedy abstrahuje od některých praktických aspektů reálného short sellingu, zejména od nákladů na vypůjčení cenných papírů, financování krátké pozice a dalších institucionálních omezení. Výsledky strategií typu combined je proto vhodné interpretovat především jako ověření, zda rekonstruovaný index sentimentu nese informaci také pro spekulování na pokles trhu.

Součástí testovacího rámce je také rozdělení dat na in-sample a out-of-sample období. In-sample část slouží k parametrické optimalizaci strategií, zatímco out-of-sample část je vyhrazena pro jejich následné nezávislé ověření. Toto rozdělení je zavedeno s cílem omezit riziko přeoptymalizace, tedy situace, kdy strategie dosahuje příznivých výsledků pouze proto, že byla přizpůsobena konkrétním historickým datům a zachytila minulý šum místo budoucího signálu. V literatuře je tento problém označován jako backtest overfitting a je spojován s tím, že při testování velkého množství alternativních konfigurací roste pravděpodobnost falešně pozitivních výsledků i zdánlivě

silných in-sample výkonů, které se následně mimo optimalizační vzorek nepotvrdí (Bailey et al., 2015).

3.5.3 Matematická formulace obchodních strategií

Po vymezení jednotného rámce backtestingu lze formálně zapsat samotná rozhodovací pravidla jednotlivých strategií. V následujících vztazích (3.23 až 3.26) označuje FGI_t hodnotu rekonstruovaného Fear & Greed Indexu v čase t . U úrovnových strategií představuje e (entry) vstupní práh a x (exit) výstupní práh. U strategií založených na klouzavých průměrech (3.27 až 3.28) značí $MA_f(t)$ rychlý klouzavý průměr indexu sentimentu o délce f a $MA_s(t)$ pomalý klouzavý průměr o délce s . Symbol p_{t+1} vyjadřuje cílovou pozici strategie pro následující obchodní krok. Horní indexy u jednotlivých vztahů rozlišují konkrétní strategii. Označení KL odpovídá strategii kontrarian_long, KC strategii kontrarian_combined, TL strategii trend_long, TC strategii trend_combined, ML strategii ma_long a MC strategii ma_combined. Pokud není splněna ani jedna z uvedených podmínek, strategie ponechává předchozí pozici beze změny. U strategií založených na klouzavých průměrech navíc na začátku časové řady, kdy ještě nelze vypočítat pomalý klouzavý průměr, setrvává v hotovosti. Samotný mechanismus vývoje hodnoty portfolia a započtení transakčních nákladů byl popsán v předchozí podkapitole 3.5.2.

Kontrariánská long-only strategie otevírá dlouhou pozici při nízké hodnotě sentimentu a uzavírá ji při dostatečně vysoké hodnotě indexu. Její rozhodovací pravidlo lze zapsat vztahem:

$$p_{t+1}^{KL} = \begin{cases} LONG, & FGI_t < e, \\ CASH, & FGI_t > x, \end{cases} \quad e < x. \quad (3.23)$$

Kontrariánská combined strategie vychází ze stejné logiky, avšak při vysoké hodnotě indexu nepřechází do hotovosti, ale do krátké pozice. Tato strategie je dána vztahem:

$$p_{t+1}^{KC} = \begin{cases} LONG, & FGI_t < e, \\ SHORT, & FGI_t > x, \end{cases} \quad e < x. \quad (3.24)$$

Trendová long-only strategie interpretuje vysoké hodnoty indexu jako potvrzení pokračujícího příznivého sentimentu. Její rozhodovací pravidlo je dáno vztahem:

$$p_{t+1}^{TL} = \begin{cases} LONG, & FGI_t > e, \\ CASH, & FGI_t < x, \end{cases} \quad e > x. \quad (3.25)$$

Trendová combined strategie rozšiřuje předchozí pravidlo o možnost obchodování na pokles trhu. Její cílová pozice je určena vztahem:

$$p_{t+1}^{TC} = \begin{cases} LONG, & FGI_t > e, \\ SHORT, & FGI_t < x, \end{cases} \quad e > x. \quad (3.26)$$

Poslední dvě strategie nejsou založeny na absolutní úrovni indexu, ale na vztahu mezi jeho krátkodobějším a dlouhodobějším trendem. U MA long-only strategie je rozhodovací pravidlo řešeno vztahem:

$$p_{t+1}^{ML} = \begin{cases} LONG, & MA_f(t) > MA_s(t), \\ CASH, & MA_f(t) < MA_s(t), \end{cases} \quad f < s. \quad (3.27)$$

MA combined strategie používá stejný princip, avšak při záporném rozdílu mezi rychlým a pomalým klouzavým průměrem otevírá krátkou pozici. Formálně ji lze vyjádřit vztahem:

$$p_{t+1}^{MC} = \begin{cases} LONG, & MA_f(t) > MA_s(t), \\ SHORT, & MA_f(t) < MA_s(t), \end{cases} \quad f < s. \quad (3.28)$$

Při rovnosti rychlého a pomalého klouzavého průměru obě strategie založené na klouzavých průměrech ponechávají dosavadní pozici beze změny.

Z uvedených vztahů plyne, že rozdíl mezi testovanými strategiemi spočívá pouze ve způsobu, jakým je signál založený na sentimentu převeden na pozici pro následující obchodní krok. První čtyři strategie vycházejí z pevně stanovených prahových hodnot indexu, poslední dvě pak z křížení rychlého a pomalého klouzavého průměru sentimentu. Samotný mechanismus simulace obchodování zůstává pro všechny varianty shodný.

3.5.4 Parametrizace strategií a grid search

V této podkapitole je popsán způsob nastavení parametrů obchodních strategií a rozsah grid search. Nejprve jsou vymezeny parametry úrovnových strategií založených na vstupních a výstupních prahových hodnotách indexu FGI. Následně jsou popsány parametry strategií založených na křížení klouzavých průměrů sentimentu. Závěrečná část podkapitoly se věnuje rozsahu testovaného parametrového prostoru, filtraci strategií s nízkou obchodní aktivitou a volbě optimalizačního kritéria v in-sample období.

Parametry úrovnových strategií

Po formálním vymezení obchodních pravidel bylo nutné stanovit parametrový prostor, v němž budou jednotlivé strategie testovány. U úrovnových strategií byly optimalizovány dva prahy, a to vstupní práh e a výstupní práh x . U kontrariánských

strategií představuje parametr e hranici strachu a parametr x hranici chamtivosti, přičemž z konstrukce strategie musí platit $e < x$. Testovaný rozsah byl proto stanoven na $e \in \{1, \dots, 49\}$ a $x \in \{50, \dots, 100\}$. Toto omezení nebylo zavedeno pouze z technických důvodů, ale především proto, aby vstupní i výstupní práh odpovídaly ekonomické logice strategie. Kombinace, v nichž by se oba prahy nacházely například ve vyšší části škály indexu, by sice mohly formálně splnit podmínku $e < x$, avšak již by neodpovídaly kontrariánskému principu vstupu při strachu a výstupu při chamtivosti. U trendových strategií je interpretace opačná. Vstupní práh zde odpovídá vysokým hodnotám sentimentu a výstupní práh nízkým hodnotám, takže musí platit $e > x$. Testovaný rozsah byl proto nastaven na $e \in \{50, \dots, 100\}$ a $x \in \{1, \dots, 49\}$. Tím bylo zajištěno, že kontrariánská i trendová logika byla parametrizována konzistentně a bez interpretačně hybridních kombinací.

Parametry MA strategií

U strategií založených na křížení klouzavých průměrů sentimentu byly optimalizovány délky rychlého a pomalého průměru. Parametr f nabýval hodnot od 1 do 10 obchodních dní, zatímco parametr s od 11 do 63 obchodních dní. Stejná parametrizace byla použita jak pro strategii `ma_long`, tak pro `ma_combined`.

Rozsah grid search

Množina testovaných kombinací parametrů byla vytvořena pro obě varianty rekonstruovaného indexu, tedy `FGI_Equal` a `FGI_OLS`, i pro všech šest testovaných strategií. V případě kontrariánských strategií tak vzniklo 9 996 konfigurací a stejný počet připadal i na strategie trendové. Úrovňové strategie dohromady vytvořily 19 992 testovaných kombinací. U strategií založených na klouzavých průměrech vzniklo 530 přípustných dvojic parametrů pro každou kombinaci strategie a varianty indexu, což vedlo k 2 120 konfiguracím. Celkový rozsah grid search tak činil 22 112 testovaných kombinací.

Filtrace strategií s nízkou obchodní aktivitou

Aby do další analýzy nevstupovaly strategie založené pouze na ojedinělých obchodech, byl zaveden minimální požadavek na obchodní aktivitu. Každá konfigurace, která v in-sample období vygenerovala méně než pět obchodů, byla z výsledků vyřazena. V konkrétním provedeném běhu bylo z celkových 22 112 konfigurací tímto filtrem odstraněno 5 523 případů a pro další hodnocení tak zůstalo zachováno 16 589 konfigurací.

Tento krok omezuje vliv parametrizací, jejichž výsledek by mohl být dán spíše nahodilostí než opakovatelným obchodním pravidlem.

Optimalizační kritérium v in-sample části

Jako hlavní optimalizační kritérium v in-sample části je zvolen ukazatel celkové výnosnosti. Tato volba vychází ze snahy ověřit, zda strategie založené na rekonstruovaném indikátoru sentimentu dosahují vyššího zhodnocení než strategie Buy and Hold na indexu S&P 500 Total Return. Jelikož jsou všechny konfigurace hodnoceny na stejném in-sample období, je jejich porovnání podle celkové výnosnosti metodicky konzistentní. Grid search procházel celý přípustný parametrový prostor a u každé konfigurace ukládal nejen celkový výnos, ale i další doplňkové charakteristiky, zejména CAGR, Sharpeho poměr (Sharpe ratio), maximální propad (maximum drawdown), Calmarův poměr (Calmar ratio) a počet transakcí, dále popsané v podkapitole 3.5.5. Tyto ukazatele slouží k posouzení, zda dosažený výnos nebyl spojen s nepřiměřeným rizikem nebo nadměrnou obchodní aktivitou. Pro následnou validaci byly jako nejlepší vybírány ty konfigurace, které v rámci dané kombinace strategie a varianty indexu dosáhly nejvyšší hodnoty celkového výnosu. Tím bylo možné jednoznačně oddělit fázi parametrické optimalizace od pozdějšího out-of-sample ověření.

3.5.5 Výkonnostní metriky a jejich výpočet

Pro vyhodnocení testovaných obchodních strategií bylo použito několik základních výkonnostních metrik, které zachycují nejen absolutní výnosnost, ale i rizikovost dosažených výsledků. Zvolená sada ukazatelů zachycuje konečné zhodnocení strategie, průměrné tempo růstu v čase i vztah mezi dosaženým výnosem a podstoupeným rizikem. V této práci jsou sledovány ukazatele celkové výnosnosti, CAGR, Sharpe ratio, Maximum drawdown a Calmar ratio. Vedle nich je evidován také počet transakcí, který nevystupuje pouze jako doplňková informace, ale zároveň slouží jako součást filtru při výběru přípustných strategií. Výpočet všech metrik je implementován jednotně pro všechny strategie v backtestovacím enginu.

Celková výnosnost a CAGR

Nejjednodušším ukazatelem je celková výnosnost strategie, označovaná jako celkový výnos (total return, TR). Ta vyjadřuje, o kolik procent se změnila hodnota portfolia mezi počátkem a koncem sledovaného období,

$$TR = \left(\frac{E_T}{E_0} - 1 \right) \cdot 100, \quad (3.29)$$

kde E_0 označuje počáteční hodnotu portfolia a E_T jeho hodnotu na konci sledovaného období. Tento ukazatel poskytuje přímou informaci o celkovém zhodnocení strategie, avšak sám o sobě nepostihuje délku investičního horizontu.

V souladu s obecnou finanční literaturou byl proto doplněn o ukazatel compound annual growth rate (CAGR), který převádí celkové zhodnocení na průměrné roční tempo růstu (Kresta, 2024). V použité implementaci je CAGR počítán jako geometrická roční míra růstu portfolia,

$$CAGR = \left(\frac{E_T}{E_0} \right)^{1/Y} - 1, \quad (3.30)$$

kde Y označuje délku sledovaného období v letech. V kódu je počet let aproximován jako podíl počtu obchodních dní a hodnoty 252, což odpovídá běžnému předpokladu o průměrném počtu obchodních dní v roce. Výstup je následně vyjádřen v procentech.

Sharpe ratio

Samotná výnosnost však pro srovnání strategií nestačí, protože neříká nic o kolísání dosažených výsledků. Z tohoto důvodu je do analýzy zahrnuto také Sharpe ratio (3.31), které poměří průměrný výnos strategie s její volatilitou. Kresta (2024) jej uvádí jako jednu z nejznámějších výkonnostních charakteristik založených na vztahu výnosu a rizika. V této práci je Sharpe ratio počítán ze série denních výnosů portfolia, přičemž je použita zjednodušená varianta bez odečtení bezrizikové sazby. Výpočet lze zapsat jako:

$$SR = \frac{\bar{r}}{\sigma(r)} \sqrt{252}, \quad (3.31)$$

kde $\bar{r}$ představuje průměrný denní výnos strategie a $\sigma(r)$ směrodatnou odchylku denních výnosů. Násobení druhou odmocninou z 252 zajišťuje anualizaci ukazatele. Vyšší hodnota Sharpe ratio tedy znamená příznivější poměr mezi dosaženým výnosem a kolísáním výnosů v čase.

Maximum drawdown a Calmar ratio

Vedle volatility je pro hodnocení obchodních strategií důležitý také rozsah největší ztráty, kterou strategie utrpěla od předchozího maxima hodnoty portfolia. Tento aspekt zachycuje maximum drawdown. Kresta (2024) jej popisuje jako maximální procentuální pokles hodnoty portfolia v čase. V rámci této práce je maximum drawdown (3.32) určeno jako nejhlubší relativní pokles od dosavadního maxima hodnoty portfolia,

$$MDD = \min_t \left(\frac{E_t - \max_{\tau \leq t} E_\tau}{\max_{\tau \leq t} E_\tau} \right) \cdot 100, \quad (3.32)$$

kde E_t označuje hodnotu portfolia v čase t a $\max_{\tau \leq t} E_\tau$ dosavadní maximum hodnoty portfolia do okamžiku t . Z této definice plyne, že ukazatel v implementaci nabývá záporných hodnot, které vyjadřují velikost největšího propadu portfolia v procentech. Čím je tato hodnota nižší, tím hlubší ztrátu strategie během sledovaného období zaznamenala.

Na maximum drawdown navazuje Calmar ratio (3.33), které porovnává anualizované tempo růstu strategie s velikostí jejího největšího propadu. Kresta (2024) uvádí Calmar ratio jako ukazatel, který na rozdíl od Sharpe ratio nepracuje se směrodatnou odchylkou, ale právě s maximálním drawdownem. V této práci je počítáno jako:

$$CR = \frac{CAGR}{|MDD|}. \quad (3.33)$$

Tento ukazatel doplňuje Sharpe ratio o jiný pohled na riziko. Zatímco Sharpe ratio postihuje celkové kolísání výnosů, Calmar ratio zdůrazňuje vztah mezi výnosem a největší zaznamenanou ztrátou. Strategie s vyšší hodnotou Calmar ratio tak dosahuje vyššího růstu při relativně menším maximálním propadu.

Počet transakcí

Vedle výše uvedených metrik je sledován také počet transakcí. V této práci nejde o počet kompletních uzavřených obchodních cyklů, ale o počet jednotlivých změn pozice. Přechod z cash do long pozice tedy představuje jednu transakci, zatímco přímý přechod z long do short pozice je interpretován jako uzavření jedné pozice a současné otevření druhé, a je proto započten jako dvě transakce. Tato veličina je následně využita i jako technický filtr při grid search, kde jsou z další analýzy vyřazovány konfigurace s méně než pěti transakcemi.

Shrnutí použité sady ukazatelů

Zvolená sada metrik umožňuje hodnotit strategie z několika vzájemně se doplňujících hledisek. Celkový výnos a CAGR zachycují absolutní a anualizovanou výnosnost, Sharpe ratio hodnotí výnos ve vztahu ke kolísání denních výsledků, maximum drawdown měří největší zaznamenaný propad a Calmar ratio propojuje tempo růstu s hloubkou této ztráty. Počet transakcí pak doplňuje obrázek o míru obchodní aktivity strategie a současně slouží jako praktické omezení při výběru parametrických konfigurací. Tím vzniká konzistentní rámec pro porovnání výkonnosti testovaných strategií v in-sample i out-of-sample části analýzy.

3.5.6 Validační schéma a benchmark

Po výběru nejlepších parametrických konfigurací v in-sample části následuje jejich ověření na samostatném out-of-sample období. In-sample část pokrývá interval od 1. 1. 1998 do 31. 12. 2015, zatímco out-of-sample období začíná 1. 1. 2016 a končí 20. 3. 2026. Smyslem tohoto rozdělení je oddělit fázi hledání parametrů od následného nezávislého ověření a tím omezit riziko přeoptymalizace.

Do out-of-sample testu nevstupovaly všechny konfigurace zachované po grid search, ale pouze ty, které v in-sample části dosáhly nejlepších výsledků. Pro každou kombinaci strategie a varianty rekonstruovaného indexu byly ponechány tři konfigurace s nejvyšší hodnotou ukazatele total return. Při šesti strategiích a dvou variantách indexu tak validační soubor tvoří celkem 36 konfigurací. Každý out-of-sample backtest současně začíná znovu s počátečním kapitálem 10 000 USD, bez přenosu otevřených pozic či kapitálové trajektorie z in-sample části. U strategií `ma_long` a `ma_combined` jsou sice klouzavé průměry na začátku out-of-sample období dopočteny s využitím předcházející historické řady, samotné obchodování i vyhodnocení výkonnosti však začíná až od prvního dne out-of-sample období.

V out-of-sample části jsou u každé konfigurace vyhodnoceny stejné metriky jako v části in-sample, konkrétně total return, CAGR, Sharpe ratio, maximum drawdown, Calmar ratio a počet transakcí. Výsledky tak lze mezi oběma obdobími přímo porovnávat. Součástí validačního schématu je také benchmark Buy and Hold na indexu S&P 500 Total Return, počítaný samostatně pro in-sample i out-of-sample období při stejném počátečním kapitálu a se stejnou sadou výkonnostních metrik. Benchmark tak představuje základní referenční linii pro interpretaci výsledků testovaných strategií.

3.6 Implementace modelu v jazyku Python

Praktická realizace celé empirické části byla provedena v jazyce Python. Implementace má modulární uspořádání, které odděluje datovou vrstvu, výpočet jednotlivých komponent indexu, konstrukci výsledného kompozitního indexu a následný backtesting obchodních strategií. Zdrojové kódy použité při implementaci modelu jsou uvedeny v příloze č. 2.

Při implementaci byly vedle samotného jazyka Python využity specializované knihovny pro práci s daty, statistické výpočty, stahování finančních časových řad, regresní analýzu, web scraping a vizualizaci výsledků. Pro práci s tabulkovými daty byla použita knihovna pandas, jejíž využití v datové analýze v jazyce Python popisuje McKinney (2022). Dále byly využity zejména knihovny numpy, yfinance, requests, pandas_datareader, statsmodels, scipy, selenium, matplotlib, joblib a tqdm.

3.6.1 Struktura projektu a datová vrstva

Projekt je členěn do složek data, components, index a strategy. Složka data obsahuje referenční historickou řadu CNN Fear & Greed Indexu, components obsahuje kód související se sedmi dílčími komponentami, index slouží k jejich sloučení, výpočtu vah, konstrukci výsledných variant indexu a jejich validaci a strategy zahrnuje backtestingový engine, optimalizační skripty a analytické výstupy.

Referenční historická řada CNN Fear & Greed Indexu je získávána automatizovaným skriptem data/fear_and_greed_dwn.py. Skript využívá knihovnu Selenium a headless prohlížeč Chrome, načte stránku portálu finhacker.cz a pomocí JavaScriptového volání extrahuje objekt window.finhackerDataPromise, z něhož vytvoří denní datovou řadu. Ta je po odfiltrování hodnot od 1. ledna 2011 ukládána do souboru fear_greed_historical.csv. Z technického hlediska je podstatné, že data nejsou získávána z přímého souboru ke stažení, ale z dynamicky načítaného obsahu webové stránky.

3.6.2 Implementace jednotlivých komponent indexu

Každá ze sedmi komponent rekonstruovaného indexu je implementována ve vlastní podsložce components. Přestože jednotlivé komponenty vycházejí z odlišných tržních ukazatelů, jejich technická architektura je podobná. Produkční skript nejprve načte nebo stáhne vstupní data, následně z nich vypočítá signál reprezentující strach nebo chamtivost na trhu, převede jej na společnou škálu 0 až 100 a výsledek uloží do

samostatného souboru *_normalized.csv. Vedle produkčních skriptů jsou v jednotlivých složkách přítomny také grid search skripty, které slouží k výběru vhodné formulace signálu, normalizační metody a délky normalizačního okna. Finální podoba každé komponenty tak nevychází z jediné předem zvolené specifikace, ale ze systematického porovnání více kandidátních variant.

Na implementační úrovni lze rozlišit tři hlavní typy datových vstupů. Komponenty Market Momentum, Market Volatility VIX a Safe Haven Demand využívají knihovnu yfinance a pracují s cenovými řadami z Yahoo Finance. Komponenty Stock Price Strength, Stock Price Breadth a Put/Call Ratio používají data získaná ze služby StockCharts prostřednictvím interního endpointu QuoteBrain. Pro komponentu Junk Bond Demand jsou využívána data z databáze FRED. Pomocnou roli přitom plní skript stockcharts_downloader.py, který slouží jako obecná šablona pro stahování historických dat ze StockCharts.

Společným principem finálně zvolených produkčních verzí komponent je normalizace pomocí rolling Z-score, která převádí původně odlišné ukazatele na společnou interpretační škálu. U proměnných, kde vyšší původní hodnota odpovídá vyšší míře strachu, je současně použita inverzní logika. To se týká komponent Put/Call Ratio, Market Volatility VIX a Junk Bond Demand. Díky této unifikaci lze následně jednotlivé složky spojit do jedné kompozitní vrstvy. Tato část tak přímo navazuje na metodický rámec popsáný v podkapitolách 3.2 a 3.3.

3.6.3 Konstrukce a validace výsledného indexu

Po výpočtu sedmi normalizovaných komponent navazuje samostatná indexová vrstva umístěná ve složce index. Prvním skriptem je 01_merge_components.py, který spojuje sedm normalizovaných komponent s referenční historickou řadou CNN Fear & Greed Indexu a se sérií S&P 500 Total Return získanou z Yahoo Finance. Výsledkem je datový soubor fgi_dataset.csv, který představuje jednotnou vstupní tabulku pro další výpočetní kroky. Na tuto vrstvu navazuje skript 02_compute_weights.py, jenž vytváří dvě varianty vah indexu. V případě varianty Equal jsou použity rovné váhy 1/7 pro každou komponentu, zatímco v případě varianty OLS jsou váhy odhadnuty pomocí lineární regrese tak, aby co nejlépe vysvětlovaly referenční řadu CNN ve společném období, pro které jsou k dispozici všechny komponenty i referenční hodnoty. Vypočtené váhy jsou ukládány do souboru fgi_weights.csv.

Na základě těchto vah sestavuje skript `03_build_index.py` dvě finální časové řady, `FGI_Equal` a `FGI_OLS`, které jsou ukládány do souboru `fgi_index_final.csv`. Konstrukce probíhá jako vážená agregace sedmi normalizovaných komponent, přičemž u varianty `OLS` je navíc zohledněn i intercept regresního modelu. Skript současně připravuje výstupní dataset tak, aby byl přímo využitelný pro validační a strategickou část projektu. Tím vzniká přímá návaznost mezi rekonstrukcí indexu a jeho dalším empirickým využitím.

Posledním krokem indexové vrstvy je validace, kterou provádí skript `04_validate_index.py`. Ten porovnává obě rekonstruované varianty indexu s referenční řadou `CNN Fear & Greed Indexu` a vypočítává základní validační metriky, zejména Pearsonův korelační koeficient, koeficient determinace, `MAE`, `MBE` a devadesátý percentil absolutní chyby. Součástí výstupu je také vizualizace v souboru `validation_chart.png`, která kombinuje časové srovnání indexových řad a souhrnné tabulky statistik. Tato implementační vrstva tedy technicky zajišťuje postup popsáný v podkapitolách 3.4.1 a 3.4.2.

3.6.4 Implementace backtestingu a analýzy strategií

Praktické využití rekonstruovaného indexu v obchodních strategiích je implementováno ve složce `strategy`. Základní nastavení celého backtestingového rámce je soustředěno v souboru `config.py`, který definuje časové rozdělení dat na in-sample a out-of-sample období, počáteční kapitál, transakční náklady, používané varianty indexu a parametrové rozsahy `grid search`. Samotný backtestingový engine je implementován v souboru `backtester.py`. Tento skript obsahuje šest strategií, konkrétně kontrariánské a trendové varianty v režimu `long-only` i `combined` a dvě strategie založené na křížení klouzavých průměrů sentimentu. Součástí stejného skriptu je i výpočet výkonnostních metrik blíže popsáných v podkapitole 3.5.5.

Proces optimalizace a validace strategií je dále rozdělen do tří navazujících skriptů. Skript `01_grid_search.py` prochází celý parametrový prostor strategií na in-sample datech a ukládá výsledky do souboru `grid_results.csv`. Výpočet je paralelizován pomocí knihovny `joblib`, aby bylo možné efektivně zpracovat velký počet kombinací. Následně skript `02_out_of_sample.py` načte nejlepší konfigurace z `grid search` a ověří je na samostatném out-of-sample období, přičemž výsledky ukládá do souboru `oos_results.csv`. U strategií založených na křížení klouzavých průměrů sentimentu je zde implementováno specifické zacházení s `warm-upem`, kdy se klouzavé průměry

počítají z celé časové řady, ale samotné obchodování začíná až v OOS části. Poslední skript 03_analysis.py z těchto výsledků generuje souhrnnou tabulku a grafy, zejména results_table.png, oos_equity_equal.png, oos_equity_ols.png a full_period.png, které slouží jako podklad pro interpretaci výsledků v empirické části práce. Skripty ve složce strategy realizují obchodní strategie odpovídající klasifikaci popsané v podkapitole 3.5.1 a současně zajišťují backtestingový rámec, parametrizaci, validační schéma i vyhodnocení metrik popsané v podkapitolách 3.5.2 až 3.5.6.

4 Výsledky empirické analýzy

Tato kapitola navazuje na metodologický rámec vymezený v předchozí části práce a soustředí se na interpretaci empirických výsledků dosažených při obchodním testování rekonstruovaného Fear & Greed Indexu. Nejprve jsou stručně představeny výsledky in-sample optimalizace, která slouží k výběru parametrických konfigurací pro následné testování. Hlavní pozornost je však věnována ověření výsledků v samostatném out-of-sample období. Právě v této části se prokazuje, zda si strategie založené na variantách FGI_Equal a FGI_OLS dokázaly udržet výkonnost i mimo vzorek, na němž byly optimalizovány. Výsledky jsou přitom posuzovány nejen podle absolutního výnosu, ale také z pohledu rizikově očištěné výkonnosti a ve srovnání s benchmarkem Buy and Hold.

4.1 In-sample optimalizace a výběr konfigurací pro out-of-sample validaci

Prvním krokem empirické analýzy byla in-sample optimalizace parametrů obchodních strategií na období od 1. 1. 1998 do 31. 12. 2015. Smyslem nebylo definitivně potvrdit obchodní využitelnost rekonstruovaného Fear & Greed Indexu, ale systematicky projít parametrický prostor jednotlivých strategií a vybrat takové konfigurace, které budou následně ověřeny v samostatném out-of-sample období. In-sample část tedy v této práci plní roli výběrového kroku, na nějž navazuje nezávislá validační fáze.

Grid search byl proveden pro všech šest testovaných strategií a pro obě varianty rekonstruovaného indexu. U úrovnových strategií byly optimalizovány vstupní a výstupní prahy sentimentu, zatímco u strategií založených na křížení klouzavých průměrů byly testovány kombinace rychlého a pomalého okna. Celkem bylo v in-sample části testováno 22 112 parametrických konfigurací. Z nich bylo 5 523 po výpočtu vyřazeno kvůli příliš nízké obchodní aktivitě, protože vykazovaly méně než pět transakcí. Do dalšího hodnocení tak vstoupilo 16 589 konfigurací. Z tohoto souboru byly pro každou kombinaci strategie a varianty indexu vybrány tři nejlepší parametrické konfigurace podle ukazatele in-sample total return, takže do out-of-sample validace postoupilo celkem 36 obchodních strategií.

Výsledky in-sample optimalizace už v této fázi ukazují, že výkonnost se mezi jednotlivými typy strategií zřetelně lišila. Jak lze pozorovat v tabulce 4.1, nejvyššího celkového výnosu i nejvyššího CAGR dosáhly kontrariánské kombinované strategie, jejichž nejlepší konfigurace překonaly hranici 400 % u varianty FGI_OLS a 500 % u

varianty FGI_Equal, zatímco anualizované tempo růstu se u nich pohybovalo blízko 10 % i nad touto hranicí. Vedle vysokého zhodnocení si zároveň udržely kladné Sharpe ratio přesahující hodnotu 0,5 a současně i nejvyšší hodnoty Calmar ratio v rámci celé skupině testovaných strategií. Jejich výsledek tak nebyl založen pouze na absolutním výnosu, ale i na příznivém vztahu mezi růstem portfolia a velikostí maximálního propadu. Také kontrariánské long strategie vykázaly velmi silné výsledky, byť s nižším celkovým výnosem než jejich kombinované protějšky.

Odlišný obraz přinášejí trendové strategie. Nejlepší konfigurace trend_long dosáhly v obou variantách indexu vysokého in-sample zhodnocení, přičemž u FGI_OLS dokonce mírně překonaly benchmark Buy and Hold v celkovém výnosu. Současně však obě varianty trend_long vykázaly vyšší Sharpe ratio než benchmark a srovnatelnou hodnotu Calmar ratio, což naznačuje příznivější poměr výnosu a rizika. Naproti tomu trend_combined zůstala za long-only variantou zřetelně pozadu. Přidání shortu zde tedy v optimalizační části nevedlo k tak výraznému zlepšení, jaké bylo patrné u kontrariánských strategií.

Podstatně horší výsledky vykázaly strategie založené na křížení klouzavých průměrů sentimentu. Varianta ma_long sice v obou případech skončila v zisku a dosáhla kladného CAGR, její výkonnost však zůstala výrazně pod úrovní benchmarku i nejlepších úroňových strategií. Ještě horší výsledek lze pozorovat u ma_combined, která jako jediná skupina strategií dosahovala i ve své nejlepší konfiguraci záporného in-sample výnosu i záporného CAGR. V kombinaci s velmi vysokým počtem transakcí to naznačuje, že právě tento způsob využití signálu byl v optimalizačním období nejméně přesvědčivý. Už in-sample část tak ukazuje, že rekonstruovaný index FGI nebyl stejně vhodný pro všechny obchodní strategie a že jeho informační hodnota závisela nejen na zvolené variantě indexu, ale i na konkrétní konstrukci obchodního pravidla.

Tabulka 4.1 neslouží jen jako technický přehled nejlepších konfigurací, ale zároveň ukazuje, z jakého typu výsledků byly vybírány parametry pro následný out-of-sample test. Sama o sobě však ještě nemůže být chápána jako důkaz robustnosti strategií. Silná in-sample výkonnost může odrážet skutečný ekonomický obsah signálu, ale stejně tak může být částečně výsledkem přizpůsobení parametrů konkrétnímu historickému vzorku. Teprve out-of-sample validace ukáže, zda vybrané konfigurace zachycují vztah mezi sentimentem a budoucím vývojem trhu, nebo zda jejich úspěch zůstal omezen pouze na optimalizační období.

Tab. 4.1: Nejlepší in-sample konfigurace pro jednotlivé kombinace strategie a varianty rekonstruovaného indexu

Strategie	Varianta	P	Ret	CAGR	Shar	Cal	MDD	T
kontrarian_combined	FGI_Equal	e = 40, x = 82	+521,2 %	+10,7 %	+0,61	+0,24	-44,6 %	85
kontrarian_combined	FGI_OLS	e = 38, x = 79	+423,8 %	+9,7 %	+0,56	+0,21	-44,9 %	81
kontrarian_long	FGI_Equal	e = 40, x = 82	+357,1 %	+8,8 %	+0,56	+0,19	-47,7 %	43
kontrarian_long	FGI_OLS	e = 38, x = 79	+315,8 %	+8,3 %	+0,53	+0,17	-47,8 %	41
ma_combined	FGI_Equal	f = 10, s = 30	-36,3 %	-2,5 %	-0,03	-0,04	-59,3 %	375
ma_combined	FGI_OLS	f = 10, s = 31	-29,7 %	-1,9 %	+0,00	-0,04	-53,6 %	339
ma_long	FGI_Equal	f = 10, s = 30	+64,8 %	+2,8 %	+0,28	+0,08	-35,1 %	188
ma_long	FGI_OLS	f = 10, s = 31	+72,8 %	+3,1 %	+0,31	+0,11	-28,9 %	170
trend_combined	FGI_Equal	e = 58, x = 8	+114,4 %	+4,3 %	+0,31	+0,11	-41,1 %	65
trend_combined	FGI_OLS	e = 54, x = 11	+136,7 %	+4,9 %	+0,34	+0,11	-46,0 %	61
trend_long	FGI_Equal	e = 58, x = 8	+189,4 %	+6,1 %	+0,47	+0,14	-42,9 %	33
trend_long	FGI_OLS	e = 54, x = 11	+203,1 %	+6,4 %	+0,49	+0,14	-45,4 %	31
Buy and Hold	IS benchmark	—	+192,8 %	+6,2 %	+0,40	+0,11	-55,3 %	0

Zdroj: Vlastní zpracování

Pozn.: *e* = entry, *x* = exit, *f* = fast, *s* = slow, *P* = parametry Ret = celkový výnos, Shar = Sharpe ratio, Cal = Calmar ratio, MDD = maximum drawdown, *T* = transakce

4.2 Out-of-sample validace obchodních strategií a srovnání s benchmarkem

Tato podkapitola představuje hlavní empirické jádro práce, protože zachycuje výsledky strategií v samostatném out-of-sample období, které již nevstupovalo do procesu optimalizace parametrů. Jejím cílem není ukázat, které konfigurace vyšly nejlépe v historickém vzorku, ale ověřit, zda si vybrané strategie dokázaly udržet výkonnost i v období, na němž nebyly kalibrovány. Nejprve je proto předloženo souhrnné srovnání nejlepších out-of-sample výsledků vůči benchmarku Buy and Hold, po němž následuje podrobnější rozbor jednotlivých typů strategií.

4.2.1 Souhrnné out-of-sample srovnání

Hlavní empirické výsledky práce přináší až out-of-sample validace na období od 1. 1. 2016 do 20. 3. 2026, v němž byly testovány konfigurace vybrané v předchozí in-sample optimalizaci. Tabulka 4.2 shrnuje vždy nejlepší out-of-sample výsledek v rámci

trojice parametrických konfigurací, které byly pro každou kombinaci strategie a varianty rekonstruovaného indexu vybrány v in-sample části podle ukazatele total return.

Souhrnné výsledky ukazují poměrně jasný obraz. V out-of-sample období žádná ze strategií nepřekonala benchmark Buy and Hold v celkovém výnosu, který dosáhl 285,4 %. To však neznamená, že by aktivní strategie byly jako celek neúspěšné. U části z nich se totiž vedle solidního zhodnocení objevil i příznivější poměr výnosu a rizika, což je patrné z hodnot Sharpe ratio, Calmar ratio i maximal drawdown. Nejvýrazněji se to projevilo u některých long-only strategií, které sice za benchmarkem zaostaly v absolutním výnosu, současně však dosáhly vyššího Sharpe ratio, srovnatelného nebo vyššího Calmar ratio a nižších maximálních propadů. Zvláště zřetelně to lze pozorovat u strategie trend_long a u nejlepší varianty kontrarian_long založené na indexu FGI_OLS.

V tabulce 4.2 lze vidět, že mezi jednotlivými strategiemi existují výrazné rozdíly v obchodní aktivitě. Zatímco trend_long pracovala pouze s 13 transakcemi za celé validační období a kontrariánské long strategie s 25 transakcemi, strategie založené na křížení klouzavých průměrů sentimentu vykazovaly výrazně vyšší frekvenci obchodování, která u ma_combined přesahovala 200 transakcí. Vyšší počet obchodů se přitom v jejich případě nepromítl do lepších výsledků. Out-of-sample validace tak neukazuje převahu strategií na bázi tržního sentimentu v absolutním výnosu, naznačuje však, že rekonstruovaný Fear & Greed Index mohl v některých konstrukcích nést ekonomicky využitelnou informaci pro řízení tržní expozice a rizika.

Tab. 4.2: Nejlepší out-of-sample výsledky jednotlivých strategií ve srovnání s benchmarkem Buy and Hold

Strategie	Varianta	P	Ret	CAGR	Shar	Cal	MDD	T
kontrarian_combined	FGI_Equal	e = 41, x = 82	+87,9 %	+6,4 %	+0,43	+0,18	-34,9 %	49
kontrarian_combined	FGI_OLS	e = 38, x = 79	+223,6 %	+12,2 %	+0,73	+0,41	-30,2 %	49
kontrarian_long	FGI_Equal	e = 41, x = 82	+174,9 %	+10,4 %	+0,68	+0,31	-33,8 %	25
kontrarian_long	FGI_OLS	e = 38, x = 79	+260,8 %	+13,4 %	+0,84	+0,47	-28,4 %	25
ma_combined	FGI_Equal	f = 10, s = 30	-34,4 %	-4,1 %	-0,14	-0,07	-54,5 %	229
ma_combined	FGI_OLS	f = 10, s = 30	-43,1 %	-5,4 %	-0,22	-0,09	-60,9 %	213
ma_long	FGI_Equal	f = 10, s = 30	+77,8 %	+5,8 %	+0,60	+0,26	-22,1 %	114
ma_long	FGI_OLS	f = 10, s = 30	+65,1 %	+5,0 %	+0,52	+0,18	-27,8 %	106
trend_combined	FGI_Equal	e = 58, x = 8	+119,7 %	+8,0 %	+0,52	+0,26	-30,6 %	27
trend_combined	FGI_OLS	e = 53, x = 11	+116,0 %	+7,8 %	+0,51	+0,26	-30,2 %	27
trend_long	FGI_Equal	e = 58, x = 8	+220,1 %	+12,1 %	+0,92	+0,45	-27,1 %	13
trend_long	FGI_OLS	e = 58, x = 11	+226,2 %	+12,3 %	+0,93	+0,45	-27,1 %	13
Buy and Hold	OOS benchmark	—	+285,4 %	+14,2 %	+0,83	+0,42	-33,8 %	0

Zdroj: Vlastní zpracování

Pozn.: *e* = entry, *x* = exit, *f* = fast, *s* = slow, *P* = parametry Ret = celkový výnos, Shar = Sharpe ratio, Cal = Calmar ratio, MDD = maximum drawdown, *T* = transakce

4.2.2 Kontrariánské strategie

Kontrariánské strategie představují v out-of-sample období důležitou část výsledků celé práce, protože naznačují, že kontrariánská interpretace rekonstruovaného Fear & Greed Indexu si zachovala určitou informační hodnotu i mimo optimalizační vzorek. Zároveň je však zřejmé, že jejich výkonnost se výrazně lišila podle zvolené varianty indexu i podle toho, zda strategie pracovala pouze s dlouhou pozicí, nebo i s možností krátké pozice. Tento rozdíl zachycuje tabulka 4.3, která uvádí out-of-sample výsledky tří nejlepších parametrických konfigurací vybraných v in-sample části pro každou kombinaci kontrariánské strategie a varianty indexu.

Nejvýrazněji se rozdíly projevily při porovnání variant FGI_Equal a FGI_OLS. U strategie kontrarian_combined dosahují tři nejlepší konfigurace s FGI_Equal out-of-sample výnosů pouze v rozmezí 66,8 % až 87,9 %, zatímco u varianty FGI_OLS se

všechny tři výsledky pohybují mezi 182,5 % a 223,6 %. Obdobný obraz je patrný i u strategie kontrarian_long. Zatímco u FGI_Equal se trojice nejlepších konfigurací pohybuje mezi 159,9 % a 174,9 %, u FGI_OLS dosahují všechny tři konfigurace výnosů nad 236 %. U kontrarian_combined se analizované tempo růstu u varianty FGI_Equal pohybuje mezi 5,2 % a 6,4 %, zatímco u FGI_OLS mezi 10,7 % a 12,2 %. U kontrarian_long dosahuje FGI_Equal hodnot 9,8 % až 10,4 %, zatímco FGI_OLS se pohybuje mezi 12,6 % a 13,4 %.

Vyšší výkonnost varianty FGI_OLS se přitom neprojevila jen v absolutním zhodnocení a CAGR, ale také v rizikově očištěných metrikách. U kontrarian_combined se Sharpe ratio pohybuje u FGI_Equal mezi 0,37 a 0,43, zatímco u FGI_OLS mezi 0,66 a 0,73. Calmar ratio zároveň roste z intervalu 0,17 až 0,18 na hodnoty 0,31 až 0,41. Podobný obraz se opakuje i u kontrarian_long, kde se Sharpe ratio u FGI_Equal pohybuje mezi 0,65 a 0,68, zatímco u FGI_OLS mezi 0,79 a 0,84. Calmar ratio zde vzrostlo z rozpětí 0,31 až 0,35 na 0,37 až 0,47. Právě u kontrariánských strategií se tedy nejzřetelněji ukazuje, že kalibrovaná varianta FGI_OLS nesla v out-of-sample období silnější a obchodně lépe využitelný signál než varianta FGI_Equal.

Stejně důležité je i srovnání long-only a combined přístupu. Z tabulky 4.3 je patrné, že v obou variantách indexu vychází kontrarian_long přesvědčivěji než kontrarian_combined. U FGI_Equal dosahuje long-only varianta nejen vyššího výnosu a vyššího CAGR, ale také vyššího Sharpe ratio. Stejná skutečnost se opakuje i u FGI_OLS, kde kontrarian_long překonává combined variantu jak v absolutním zhodnocení, tak v rizikově očištěné výkonnosti. Nejlepší konfigurace kontrarian_long s FGI_OLS dosáhla Sharpe ratio 0,84, tedy mírně vyšší hodnoty než benchmark Buy and Hold, který ve stejném období vykázal hodnotu 0,83. Současně dosáhla i vyššího Calmar ratio, konkrétně 0,47 oproti 0,42, a nižšího maximálního drawdownu, který činil 28,4 % oproti 33,8 % u benchmarku. Ani tato strategie však nepřekonala Buy and Hold v celkovém výnosu ani v CAGR.

Výsledky kontrariánských strategií proto nepodporují závěr, že by kontrariánská logika umožnila v out-of-sample období jednoznačně porazit pasivní držení trhu v absolutním výnosu. Ukazují ale, že by mohla nabídnout atraktivnější poměr výnosu a rizika, a to zejména v long-only variantě postavené na indexu FGI_OLS. Z tabulky 4.3 je navíc patrné, že počet transakcí se v rámci jednotlivých kontrariánských strategií mezi nejlepšími třemi konfiguracemi prakticky neměnil. U combined variant činil vždy 49

transakcí a u long-only variant 25 transakcí. Rozdíly ve výkonnosti tedy nelze vysvětlit odlišnou frekvencí obchodování, ale spíše samotnou konstrukcí signálu a variantou použitého indexu. Zároveň platí, že přesvědčivější byly long-only konstrukce než varianty rozšířené o krátkou pozici. To je pro interpretaci těchto výsledků podstatné, protože short je v backtestu modelován zjednodušeně a long-only varianta proto působí metodologicky i ekonomicky obhajitelněji.

Tab. 4.3: Top 3 out-of-sample konfigurace kontrariánských strategií

Strategie	Varianta	P	Ret	CAGR	Shar	Cal	MDD	T
kontrarian_combined	FGI_Equal	e = 40, x = 82	+87,4 %	+6,4 %	+0,43	+0,18	-34,9 %	49
kontrarian_combined	FGI_Equal	e = 41, x = 82	+87,9 %	+6,4 %	+0,43	+0,18	-34,9 %	49
kontrarian_combined	FGI_Equal	e = 36, x = 82	+66,8 %	+5,2 %	+0,37	+0,17	-30,2 %	49
kontrarian_combined	FGI_OLS	e = 38, x = 79	+223,6 %	+12,2 %	+0,73	+0,41	-30,2 %	49
kontrarian_combined	FGI_OLS	e = 43, x = 79	+182,5 %	+10,7 %	+0,66	+0,31	-34,9 %	49
kontrarian_combined	FGI_OLS	e = 42, x = 79	+183,7 %	+10,8 %	+0,66	+0,31	-34,9 %	49
kontrarian_long	FGI_Equal	e = 40, x = 82	+174,6 %	+10,4 %	+0,68	+0,31	-33,8 %	25
kontrarian_long	FGI_Equal	e = 36, x = 82	+159,9 %	+9,8 %	+0,65	+0,35	-28,4 %	25
kontrarian_long	FGI_Equal	e = 41, x = 82	+174,9 %	+10,4 %	+0,68	+0,31	-33,8 %	25
kontrarian_long	FGI_OLS	e = 38, x = 79	+260,8 %	+13,4 %	+0,84	+0,47	-28,4 %	25
kontrarian_long	FGI_OLS	e = 43, x = 79	+236,0 %	+12,6 %	+0,79	+0,37	-33,8 %	25
kontrarian_long	FGI_OLS	e = 42, x = 79	+236,9 %	+12,7 %	+0,79	+0,37	-33,8 %	25
Buy and Hold	OOS benchmark	—	+285,4 %	+14,2 %	+0,83	+0,42	-33,8 %	0

Zdroj: Vlastní zpracování

Pozn.: e = entry, x = exit, f = fast, s = slow, P = parametry Ret = celkový výnos, Shar = Sharpe ratio, Cal = Calmar ratio, MDD = maximum drawdown, T = transakce

4.2.3 Trendové strategie

Trendové strategie představují v out-of-sample období jednu z nejstabilnějších částí celé empirické analýzy. Na rozdíl od kontrariánských strategií zde není hlavním rysem výrazný rozdíl mezi FGI_Equal a FGI_OLS, ale spíše konzistence výsledků napříč jednotlivými konfiguracemi, zejména u long-only variant. V tabulce 4.4 lze pozorovat out-of-sample výsledky tří nejlepších in-sample konfigurací pro každou kombinaci

trendové strategie a varianty indexu. Už na první pohled je patrné, že trendové strategie si ve validačním období udržely kladnou výkonnost ve všech případech.

Nejlépe vychází strategie trend_long. U varianty FGI_Equal se trojice vybraných konfigurací pohybuje v intervalu 217,8 % až 220,1 % z hlediska total return, zatímco CAGR se drží mezi 12,0 % a 12,1 %. U FGI_OLS je obraz velmi podobný, přičemž nejlepší konfigurace dosáhla výnosu 226,2 % a CAGR 12,3 %. Rozdíly mezi jednotlivými nastaveními jsou zde malé, což je důležité. Výsledek tedy nestojí na jednom izolovaném parametru, ale působí robustně napříč celou trojicí vybraných parametrů.

Vedle absolutního výnosu je u trend_long výrazný také příznivý poměr výnosu a rizika. Sharpe ratio se u všech šesti konfigurací pohybuje mezi 0,89 a 0,93, tedy nad úrovní benchmarku Buy and Hold, který ve stejném období vykázal hodnotu 0,83. Podobně i Calmar ratio dosahuje u trend_long hodnot 0,43 až 0,46, zatímco benchmark činí 0,42. Zároveň jsou maximální propady portfolia ve všech případech nižší než u pasivního benchmarku. Trend_long tak sice Buy and Hold nepřekonává v total return ani v CAGR, nabízí však přesvědčivější risk-adjusted profil.

Méně výrazné, ale stále solidní výsledky přináší trend_combined. U varianty FGI_Equal se tři konfigurace pohybují mezi 116,4 % a 119,7 % total return, u FGI_OLS mezi 110,3 % a 116,0 %. CAGR se v obou variantách drží mezi 7,6 % a 8,0 %. Sharpe i Calmar ratio jsou zde sice kladné a poměrně stabilní, ale zůstávají zřetelně pod úrovní trend_long. Přidání krátké pozice tedy u trendových strategií nevedlo k obdobnému zlepšení, jaké bylo možné pozorovat u nejlepších long-only strategií.

Z tabulky 4.4 je zároveň dobře vidět, že trendové strategie patří k nejméně obchodně aktivním v celém souboru testovaných přístupů. U trend_long činil počet transakcí pouze 13 a u trend_combined 27, přičemž tato hodnota zůstávala v rámci jednotlivých trojic prakticky neměnná. To naznačuje, že dosažené výsledky nebyly založeny na vysoké frekvenci obchodování. Právě v této části výsledků se proto nejzřetelněji ukazuje, že trendová interpretace rekonstruovaného FGI mohla nést ekonomicky smysluplnou informaci i mimo optimalizační vzorek.

Celkově lze říci, že trendové strategie, a zejména trend_long, patří v out-of-sample období k nejpřesvědčivějším výsledkům celé práce. Nepřinášejí sice převahu nad Buy and Hold v absolutním výnosu, ale vykazují velmi stabilní výsledky napříč vybranými konfiguracemi, nízkou obchodní aktivitu a zároveň příznivý poměr mezi výnosem a

podstoupeným rizikem. Právě tato kombinace činí z trend_long jednu z nejlépe obhajitelných strategií v celé empirické části.

Tab. 4.4: Out-of-sample výsledky tří nejlepších in-sample konfigurací trendových strategií

Strategie	Varianta	P	Ret	CAGR	Shar	Cal	MDD	T
trend_combined	FGI_Equal	e = 58, x = 8	+119,7 %	+8,0 %	+0,52	+0,26	-30,6 %	27
trend_combined	FGI_Equal	e = 59, x = 8	+116,4 %	+7,9 %	+0,51	+0,26	-30,6 %	27
trend_combined	FGI_Equal	e = 59, x = 7	+118,8 %	+8,0 %	+0,52	+0,26	-30,6 %	27
trend_combined	FGI_OLS	e = 54, x = 11	+110,3 %	+7,6 %	+0,50	+0,24	-31,0 %	27
trend_combined	FGI_OLS	e = 53, x = 11	+116,0 %	+7,8 %	+0,51	+0,26	-30,2 %	27
trend_combined	FGI_OLS	e = 52, x = 11	+116,0 %	+7,8 %	+0,51	+0,26	-30,2 %	27
trend_long	FGI_Equal	e = 58, x = 8	+220,1 %	+12,1 %	+0,92	+0,45	-27,1 %	13
trend_long	FGI_Equal	e = 59, x = 8	+217,8 %	+12,0 %	+0,91	+0,44	-27,1 %	13
trend_long	FGI_Equal	e = 59, x = 7	+218,9 %	+12,1 %	+0,91	+0,45	-27,1 %	13
trend_long	FGI_OLS	e = 54, x = 11	+212,6 %	+11,8 %	+0,89	+0,43	-27,3 %	13
trend_long	FGI_OLS	e = 53, x = 11	+216,7 %	+12,0 %	+0,90	+0,46	-26,2 %	13
trend_long	FGI_OLS	e = 58, x = 11	+226,2 %	+12,3 %	+0,93	+0,45	-27,1 %	13
Buy and Hold	OOS benchmark	—	+285,4 %	+14,2 %	+0,83	+0,42	-33,8 %	0

Zdroj: Vlastní zpracování

Pozn.: e = entry, x = exit, f = fast, s = slow, P = parametry Ret = celkový výnos, Shar = Sharpe ratio, Cal = Calmar ratio, MDD = maximum drawdown, T = transakce

4.2.4 Strategie založené na křížení klouzavých průměrů sentimentu

Strategie založené na křížení klouzavých průměrů sentimentu jsou v out-of-sample období horší než úrovnové kontrariánské a trendové přístupy. Tabulka 4.5 shrnuje out-of-sample výsledky tří nejlepších in-sample konfigurací pro strategie ma_long a ma_combined, a to pro obě varianty rekonstruovaného indexu. Na rozdíl od předchozích skupin strategií zde nevystupuje do popředí pouze rozdíl mezi FGI_Equal a FGI_OLS, ale především rozdíl mezi long-only a combined konstrukcí. Je patrné, že právě tato volba měla pro konečný výsledek zásadní význam.

Nejlépe z této skupiny strategií vychází strategie `ma_long`. Všechny její sledované konfigurace skončily v out-of-sample období v zisku, přičemž u varianty `FGI_Equal` se celkový výnos pohyboval mezi 60,9 % a 77,8 % a CAGR mezi 4,8 % a 5,8 %. U varianty `FGI_OLS` byly výsledky o něco horší, s výnosem v rozmezí 50,4 % až 65,1 % a CAGR mezi 4,1 % a 5,0 %. Výsledek `ma_long` tedy nelze označit za vyloženě neúspěšný, zároveň však zůstává zřetelně pod úrovní benchmarku Buy and Hold i pod úrovní nejlepších kontrariánských a trendových strategií. Výhodou této strategie jsou nižší maximální propady portfolia, které se u všech konfigurací pohybují pod úrovní benchmarku. Z hlediska Sharpe a Calmar ratio však `ma_long` pasivní benchmark nepřekonává.

Podstatně horší je strategie `ma_combined`. Ve všech šesti sledovaných konfiguracích dosahuje záporného out-of-sample výnosu i záporného CAGR. U `FGI_Equal` se total return pohybuje mezi -34,4 % a -46,3 %, u `FGI_OLS` mezi -43,1 % a -53,4 %. Stejně nepříznivě vyznívají i rizikově očištěné metriky. Sharpe ratio je ve všech případech záporné a Calmar ratio se rovněž drží v záporných hodnotách. Špatné výsledky této strategie přitom nelze vysvětlit jednou neúspěšnou konfigurací. Špatné výsledky jsou přítomny napříč celou trojicí vybraných nastavení i napříč oběma variantami indexu.

Vztah mezi obchodní aktivitou a výslednou výkonností je u těchto strategií patrný velmi zřetelně. Z tabulky 4.5 vyplývá, že `ma_long` realizovala přibližně 100 až 124 transakcí, zatímco `ma_combined` se pohybovala mezi 209 a 247 transakcemi. Právě tato skupina tak patří k nejaktivněji obchodujícím strategiím v celém souboru obchodních strategií. Vysoká frekvence obchodování se však do lepší výkonnosti nepromítla. Spíše naopak. Výsledky naznačují, že samotná změna krátkodobého a dlouhodobého trendu sentimentu nebyla pro obchodování indexu S&P 500 dostatečně silným signálem, zejména pokud byla strategie rozšířena i o krátkou pozici.

Zajímavý je i rozdíl mezi oběma variantami rekonstruovaného indexu. Zatímco u kontrariánských strategií vycházel `FGI_OLS` výrazně lépe než `FGI_Equal`, u MA strategií se takový obraz neopakuje. U `ma_long` je naopak mírně lepší varianta `FGI_Equal` a u `ma_combined` nepřináší `FGI_OLS` žádné zlepšení. To naznačuje, že kalibrace vah na historický CNN index nepomáhá stejně ve všech typech strategií.

Lze konstatovat, že výsledky MA strategií potvrzují, že indikátor sentimentu nelze využívat mechanicky v každém typu obchodního pravidla. Strategie `ma_combined` byla

v rámci celé empirické části nejslabší. Rozdíl mezi oběma MA přístupy proto podporuje hlavní závěr práce. Využitelnost rekonstruovaného FGI nezávisí pouze na samotném indikátoru sentimentu, ale také na konkrétní konstrukci obchodní strategie.

Tab. 4.5: Top 3 out-of-sample konfigurace strategií založených na křížení klouzavých průměrů sentimentu

Strategie	Varianta	P	Ret	CAGR	Shar	Cal	MDD	T
ma_combined	FGI_Equal	f = 10, s = 30	-34,4 %	-4,1 %	-0,14	-0,07	-54,5 %	229
ma_combined	FGI_Equal	f = 8, s = 29	-43,4 %	-5,4 %	-0,22	-0,10	-52,7 %	247
ma_combined	FGI_Equal	f = 8, s = 30	-46,3 %	-5,9 %	-0,25	-0,11	-56,0 %	239
ma_combined	FGI_OLS	f = 10, s = 31	-45,5 %	-5,8 %	-0,24	-0,10	-60,3 %	209
ma_combined	FGI_OLS	f = 10, s = 30	-43,1 %	-5,4 %	-0,22	-0,09	-60,9 %	213
ma_combined	FGI_OLS	f = 9, s = 32	-53,4 %	-7,2 %	-0,32	-0,11	-65,3 %	209
ma_long	FGI_Equal	f = 10, s = 30	+77,8 %	+5,8 %	+0,60	+0,26	-22,1 %	114
ma_long	FGI_Equal	f = 8, s = 29	+65,1 %	+5,0 %	+0,53	+0,22	-23,4 %	124
ma_long	FGI_Equal	f = 8, s = 30	+60,9 %	+4,8 %	+0,51	+0,22	-21,8 %	120
ma_long	FGI_OLS	f = 10, s = 31	+61,7 %	+4,8 %	+0,50	+0,18	-27,3 %	104
ma_long	FGI_OLS	f = 10, s = 30	+65,1 %	+5,0 %	+0,52	+0,18	-27,8 %	106
ma_long	FGI_OLS	f = 9, s = 32	+50,4 %	+4,1 %	+0,45	+0,14	-29,3 %	104
Buy and Hold	OOS benchmark	—	+285,4 %	+14,2 %	+0,83	+0,42	-33,8 %	0

Zdroj: Vlastní zpracování


Pozn.: e = entry, x = exit, f = fast, s = slow, P = parametry Ret = celkový výnos, Shar = Sharpe ratio, Cal = Calmar ratio, MDD = maximum drawdown, T = transakce

Grafické srovnání out-of-sample equity křivek

Po vyhodnocení jednotlivých skupin strategií je vhodné výsledky doplnit také grafickým pohledem na vývoj hodnoty portfolia v čase. Zatímco předchozí tabulky zachycují konečný stav prostřednictvím souhrnných metrik, grafy 4.1 a 4.2 ukazují samotný průběh out-of-sample equity křivek a umožňují lépe posoudit stabilitu jednotlivých strategií v čase.

Na grafu 4.1 jsou zachyceny out-of-sample equity křivky vybraných strategií založených na variantě FGI_Equal. Vizuálně je zde nejlepší strategie trend_long, která se po většinu sledovaného období drží nejbližší benchmarku Buy and Hold a ze všech


aktivních strategií vykazuje nejplynulejší růst. Přestože benchmark v závěru období zůstává výše, trend_long se mu v několika delších úsecích relativně přibližuje. Kontrariánské strategie jsou při využití u varianty FGI_Equal horší. Kontrarian_long sice vykazuje kladný a dlouhodobě rostoucí profil, avšak za trend_long zřetelně zaostává. Ještě horší je kontrarian_combined, jejíž křivka se od roku 2021 od benchmarku postupně vzdaluje. U MA strategií je situace nejméně přesvědčivá. Strategie ma_long sice zůstává po celé období v zisku, ale její růst je pozvolný a konečná hodnota portfolia zůstává výrazně pod nejlepšími úrovněnými strategiemi. Naproti tomu ma_combined se prokazuje jako jednoznačně nejslabší strategie, která nedokáže navázat na růst trhu.



*Graf 4.1: Out-of-sample equity křivky vybraných strategií založených na variantě FGI_Equal v období od 1. 1. 2016 do 20. 3. 2026.
Zdroj: Vlastní zpracování*

Na grafu 4.2 je ukázána výkonnost strategií založených na variantě FGI_OLS. Zde se projeví, že kalibrace vah měla dopad především na kontrariánské přístupy. Největší posun je patrný u strategií kontrarian_long a kontrarian_combined, jejichž křivky se oproti variantě FGI_Equal posouvají výrazně výše a v některých úsecích se přibližují benchmarku podstatně těsněji než v grafu 4.1. Zvláště kontrarian_long působí ve variantě FGI_OLS lépe než při použití u varianty FGI_Equal. Také kontrarian_combined zde vykazuje lepší vývoj než v grafu 4.1. Naopak výkonnost trendových strategií zůstává v obou grafech podobná. Trend_long si zde drží velmi stabilní výkonnost a potvrzuje, že není závislá na jediné variantě indexu. U trend_combined se také žádný výrazný posun neobjevuje. Ještě zřetelnější je to u MA

strategií, kde FGI_OLS nepřináší vizuálně přesvědčivé zlepšení. Ma_combined i nadále představuje nejslabší křivku celého souboru obchodních strategií.



Graf 4.2: Out-of-sample equity křivky vybraných strategií založených na variantě FGI_OLS v období od 1. 1. 2016 do 20. 3. 2026.

Zdroj: Vlastní zpracování

Při společném pohledu na oba grafy je patrné, že strategie Buy and Hold dosahuje v závěru období vyšší výnosnosti než všechny aktivní strategie. Zatímco u varianty FGI_Equal působí nejpřesvědčivěji trend_long, u FGI_OLS se výrazně zlepšují kontrariánské strategie, zejména kontrarian_long. Přínos varianty FGI_OLS se tak nejzřetelněji projevuje právě u kontrariánských strategií.

4.3 Srovnání konstrukčních variant strategií

Předchozí podkapitoly hodnotily jednotlivé skupiny strategií zvlášť. Tato podkapitola proto shrnuje hlavní výsledky napříč strategiemi a zaměřuje se na to, která interpretace sentimentu a která konstrukce obchodního pravidla se v out-of-sample období osvědčila nejlépe. Jak ukazují tabulky 4.3 až 4.5 a grafy 4.1 a 4.2, rekonstruovaný Fear & Greed Index nepůsobil jako univerzální signál pro všechny typy strategií. Jeho obchodní využitelnost se naopak výrazně lišila podle toho, zda byl sentiment interpretován kontrariánsky nebo trendově a zda byla strategie konstruována jako long-only nebo combined.

4.3.1 Kontrariánská versus trendová interpretace sentimentu

Srovnání kontrariánského a trendového přístupu nevede k úplně jednoznačnému vítězi, protože výsledky závisely na použité variantě indexu. Jak vyplývá z tabulek 4.3 a

4.4, u varianty FGI_Equal jsou lepší trendové strategie, zejména trend_long, která dosáhla vysokého out-of-sample výnosu, vysokého CAGR, nízkého počtu transakcí a současně příznivého poměru výnosu a rizika. Stejnou skutečnost potvrzuje i graf 4.1, na němž se trend_long drží ze všech aktivních strategií nejbližší benchmarku Buy and Hold a zároveň vykazuje nejplynulejší růst. V tomto smyslu se ukázalo, že sentiment mohl při použití varianty FGI_Equal fungovat spíše jako signál pokračování převládajícího trendu než jako signál návratu k průměru.

Odlišný obraz však přinesla varianta FGI_OLS. Jak lze pozorovat v tabulce 4.3 a současně i v grafu 4.2, právě zde se výrazně zlepšily kontrariánské strategie, a to zejména kontrarian_long, která se výkonností i rizikově očištěnými metrikami přiblížila nejlepším trendovým strategiím. Kontrariánská interpretace sentimentu tedy v práci nevyšla jako slabá nebo nefunkční. Naopak se ukázalo, že tyto strategie mohou nést velmi silný obchodní signál.

4.3.2 Long-only versus combined přístup

Jasný závěr nabízí srovnání long-only a combined přístupů. Jak je patrné z tabulek 4.3 až 4.5, ve většině sledovaných případů působily lépe long-only strategie. Nejzřetelnější je to u trendových a MA přístupů. Přidání shortu tedy vedlo ke zhoršení výsledků.

Shrnutí hlavních rozdílů

Souhrnně lze říci, že nejpresvědčivější výsledky v práci nabídly long-only úroňové strategie, a to zejména trend_long a kontrarian_long. Jak ukazují předchozí tabulky 4.3 až 4.5 i oba souhrnné grafy 4.1 a 4.2, trend_long působí velmi stabilně napříč oběma variantami indexu, zatímco kontrarian_long výrazně posiluje zejména při použití u varianty FGI_OLS. Naproti tomu strategie založené na křížení klouzavých průměrů sentimentu zůstaly horší, přičemž varianta ma_combined představovala nejhorší konstrukci celé empirické části. Rekonstruovaný Fear & Greed Index se tak neukázal jako univerzálně silný signál pro všechny typy obchodních pravidel, ale spíše jako indikátor, jehož ekonomická využitelnost závisí na konkrétním způsobu interpretace sentimentu i na zvolené konstrukci strategie.

4.4 Shrnutí výsledků ve vztahu k cíli práce

Cílem diplomové práce bylo rekonstruovat CNN Fear & Greed Index pro delší historické období a následně ověřit, zda lze takto rekonstruovaný indikátor sentimentu

využít jako vstupní signál při tvorbě obchodních strategií. Ve vztahu k tomuto cíli byla nejprve provedena rekonstrukce indexu za období let 1998 až 2026. Pro jednotlivé komponenty byly využity veřejně dostupné datové zdroje, které byly normalizovány a agregovány do dvou variant rekonstruovaného indexu.

Kvalita rekonstrukce byla ověřena porovnáním s historickými hodnotami CNN Fear & Greed Indexu v období 2011 až 2026. U obou variant byla dosažena vysoká shoda s referenční řadou, přičemž varianta FGI_OLS dosáhla mírně lepší shody s CNN FGI než varianta FGI_Equal. Rekonstruovaný index proto poskytl dostatečný metodický základ pro navazující testování obchodních strategií.

Poté byly rekonstruované indexy využity jako vstupní signál v obchodních strategiích. Testovány byly kontrariánské, trendové i MA strategie, a to ve variantách long-only a combined. Na základě out-of-sample testování nebylo prokázáno, že by některá ze strategií dokázala překonat benchmark Buy and Hold z hlediska absolutního výnosu. Zároveň však bylo zjištěno, že některé long-only strategie dosahovaly příznivějšího vztahu mezi výnosem a rizikem, zejména díky nižším maximálním propadům portfolia. Přínos práce tak spočívá především v rekonstrukci delší historické řady indexu, jejím validačním ověření a následném otestování její obchodní využitelnosti v jednotném backtestovacím rámci.

4.5 Diskuse výsledků ve vztahu k teorii a omezením práce

Tato podkapitola shrnuje, jak lze dosažené výsledky interpretovat ve vztahu k teoretickým východiskům práce, a zároveň vymezuje jejich hlavní omezení. V první části jsou empirická zjištění konfrontována s hypotézou efektivních trhů, behaviorálním pojetím trhu a adaptivní hypotézou trhů. Druhá část se zaměřuje na metodická a datová omezení, která mohou ovlivňovat vypovídací schopnost prezentovaných výsledků.

4.5.1 Diskuse výsledků ve vztahu k teorii

Na základě out-of-sample testování nelze konstatovat, že by strategie založené na rekonstruovaném Fear & Greed Indexu jednoznačně překonávaly benchmark Buy and Hold z hlediska absolutního výnosu. Výsledky tedy neumožňují tvrdit, že polosilná forma EMH neplatí. Přesto bylo u některých strategií dosaženo příznivějšího vztahu mezi výnosem a rizikem a nižších maximálních propadů portfolia než u benchmarku. Informační hodnotu rekonstruovaného indexu tak lze považovat za ekonomicky

relevantní, nikoli však za dostatečně silnou a univerzální pro systematické překonávání trhu.

Z pohledu behaviorálních financí lze tyto poznatky interpretovat jako omezenou podporu předpokladu, že tržní sentiment může souviset s dočasnými odchylkami cen od fundamentální hodnoty. U kontrariánských strategií byla testována logika mean reversion, tedy předpoklad, že extrémní strach nebo chamtivost mohou předcházet následné korekci trhu. U trendových strategií, zejména u varianty trend_long, byla naopak testována logika momentum, podle níž může převládající nálada na trhu určitou dobu pokračovat. Relativně silnější výsledky kontrariánských i trendových strategií proto nejsou nutně v rozporu. Spíše naznačují, že mean reversion a momentum mohou působit na odlišných horizontech a za odlišných tržních podmínek.

Výsledky lze současně interpretovat také v rámci adaptivní hypotézy trhů. Obchodní využitelnost rekonstruovaného indexu nebyla ve všech strategiích stejná a výrazně závisela na konkrétní konstrukci obchodního pravidla. To je patrné například ze srovnání long-only a combined přístupů, kde přidání krátkých pozic většinou nevedlo ke zlepšení výkonnosti. Tento závěr odpovídá představě, že účinnost obchodních pravidel se může měnit podle tržního prostředí, konstrukce strategie a způsobu využití indikátoru sentimentu.

4.5.2 Omezení empirické části práce

Přestože diplomová práce přináší ucelený empirický rámec od rekonstrukce indexu až po out-of-sample validaci strategií, je nutné její výsledky interpretovat s vědomím několika omezení. Prvním omezením je samotná povaha CNN Fear & Greed Indexu. CNN nezveřejňuje úplnou metodiku výpočtu, zejména přesný způsob normalizace jednotlivých komponent. Rekonstrukce indexu proto nutně představuje aproximaci založenou na veřejně dostupném popisu metodiky a na vlastních implementačních rozhodnutích autora práce. S tím souvisí i skutečnost, že referenční historická řada CNN Fear & Greed Indexu není získávána přímo z oficiálního archivu CNN, ale z veřejně dostupného datasetu portálu finhacker.cz, který v práci slouží jako nejlepší dosažitelný validační benchmark.

Druhým omezením je konstrukce samotného backtestovacího rámce. Kombinované strategie využívají modelovanou krátkou pozici, která abstrahuje od nákladů financování short pozice, nákladů na zapůjčení aktiv i dalších omezení reálného

short sellingu. Výsledky těchto strategií je proto vhodné chápat především jako test toho, zda signál sentimentu nese informaci pro obchodování na pokles trhu, nikoli jako plně realistickou simulaci všech podmínek skutečného short sellingu. Z tohoto hlediska jsou long-only výsledky ekonomicky přímočařeji interpretovatelné.

Třetí omezení souvisí s optimalizačním postupem. Parametrické konfigurace byly v in-sample části vybírány podle ukazatele total return, a právě na tomto základě byly následně postoupeny do out-of-sample validace. Jiná volba optimalizačního kritéria, například Sharpe nebo Calmar ratio, by mohla vést k odlišnému výběru konfigurací a potenciálně i k odlišným výsledkům. Přestože je zvolený postup konzistentní a transparentní, je třeba jej chápat jako jednu z možných variant empirického nastavení, nikoli jako jedinou možnou.

Čtvrtým omezením je samotná povaha validačního období. Out-of-sample část sice představuje samostatný a metodologicky správně oddělený úsek dat, stále však jde pouze o jednu konkrétní historickou trajektorii trhu v období let 2016 až 2026. Výsledky proto nelze bez dalšího výzkumu zobecnit na všechny budoucí tržní režimy. Zvláště důležité je to u strategií založených na tržním sentimentu, jejichž výkonnost může být citlivá na výskyt období zvýšené tržní nejistoty, na délku trendových úseků i na rychlost následného zotavení trhu. Podobně je omezen také použitý benchmark, který je v práci reprezentován strategií Buy and Hold na indexu S&P 500 Total Return. Práce tedy neposkytuje srovnání s širší sadou alternativních benchmarků ani s jinými třídami aktiv.

I přes uvedená omezení však zůstává metodický rámec práce konzistentní a výsledky lze považovat za relevantní příspěvek k otázce, zda je možné rekonstruovaný indikátor sentimentu využít v obchodních strategiích. Omezení zde proto nesnižují hodnotu práce jako celku, ale vymezují hranice, v nichž je vhodné její závěry interpretovat.

5 Závěr

Cílem diplomové práce bylo rekonstruovat CNN Fear & Greed Index pro delší historické období amerického akciového trhu a ověřit, zda lze takto vytvořený indikátor sentimentu využít při tvorbě a testování obchodních strategií. Z veřejně dostupných dat byla sestavena rekonstruovaná denní řada indexu za období let 1998 až 2026, čímž byl rozšířen časový horizont oproti veřejně dostupným hodnotám CNN FGI.

Rekonstrukce byla provedena ve dvou variantách, FGI_Equal a FGI_OLS. Porovnáním s referenčními hodnotami CNN FGI v období let 2011 až 2026 byla u obou variant zjištěna vysoká shoda s CNN FGI, přičemž FGI_OLS dosáhla mírně lepší shody než varianta FGI_Equal.

Na obě varianty indexu bylo následně aplikováno šest obchodních strategií zahrnujících kontrariánský i trendový přístup, long-only i kombinované strategie využívající short a strategie založené na křížení klouzavých průměrů sentimentu. Strategie byly nejprve optimalizovány v in-sample období let 1998 až 2015 přičemž jako optimalizační kritérium byl použit celkový výnos. Poté byly strategie testovány v samostatném out-of-sample období let 2016 až 2026.

Na základě out-of-sample testování nebylo prokázáno, že by některá z testovaných strategií překonala benchmark Buy and Hold z hlediska celkového výnosu. U některých strategií však byl ve srovnání s benchmarkem dosažen příznivější vztah mezi výnosem a rizikem, zejména díky nižšímu maximálnímu propadu portfolia a vyšším hodnotám Sharpe a Calmar ratio.

Hlavní přínos práce spočívá v rekonstrukci CNN Fear & Greed Indexu pro delší historické období, v ověření kvality této rekonstrukce a v jejím systematickém otestování v jednotném backtestovacím rámci. Ve vztahu k cíli vymezenému v úvodu tak bylo provedeno jak sestavení delší časové řady indexu, tak i ověření její využitelnosti při tvorbě obchodních strategií.

Seznam použité literatury

BAILEY, David H.; BORWEIN, Jonathan M.; LÓPEZ DE PRADO, Marcos a ZHU, Qiji Jim, 2015. *The Probability of Backtest Overfitting*. Online, working paper. SSRN. Dostupné z: <https://doi.org/10.2139/ssrn.2326253>. [citováno 2026-04-24].

BAKER, Malcolm a WURGLER, Jeffrey, 2006. Investor Sentiment and the Cross-Section of Stock Returns. Online. *The Journal of Finance*. Vol. 61, no. 4, s. 1645-1680. Dostupné z: <https://doi.org/10.1111/j.1540-6261.2006.00885.x>. [citováno 2026-04-24].

BAKER, Malcolm a WURGLER, Jeffrey, 2007. Investor Sentiment in the Stock Market. Online. *Journal of Economic Perspectives*. Vol. 21, no. 2, s. 129-151. Dostupné z: <https://doi.org/10.1257/jep.21.2.129>. [citováno 2026-04-24].

BRUCE, Peter a BRUCE, Andrew, 2017. *Practical Statistics for Data Scientists: 50 Essential Concepts*. 1st ed. Sebastopol: O'Reilly Media. ISBN 978-1-491-95296-2.

CBOE EXCHANGE, INC., 2019. *Cboe Volatility Index*. Online, white paper. Chicago: Cboe Exchange. Dostupné z: https://www.sfu.ca/~poitras/419_VIX.pdf. [citováno 2026-04-24].

CLARKE, Roger G. a STATMAN, Meir, 1998. Bullish or Bearish? Online. *Financial Analysts Journal*. Vol. 54, no. 3, s. 63-72. Dostupné z: <https://doi.org/10.2469/faj.v54.n3.2182>. [citováno 2026-04-24].

CNN BUSINESS, 2026. *Fear & Greed Index*. Online. Dostupné z: <https://edition.cnn.com/markets/fear-and-greed>. [citováno 2026-04-24].

DE BONDT, Werner F. M. a THALER, Richard, 1985. Does the Stock Market Overreact? Online. *The Journal of Finance*. Vol. 40, no. 3, s. 793-805. Dostupné z: <https://doi.org/10.1111/j.1540-6261.1985.tb05004.x>. [citováno 2026-04-24].

DE LONG, J. Bradford; SHLEIFER, Andrei; SUMMERS, Lawrence H. a WALDMANN, Robert J., 1990. Noise Trader Risk in Financial Markets. Online. *Journal of Political Economy*. Vol. 98, no. 4, s. 703-738. Dostupné z: <https://doi.org/10.1086/261703>. [citováno 2026-04-24].

FAMA, Eugene F., 1970. Efficient Capital Markets: A Review of Theory and Empirical Work. Online. *The Journal of Finance*. Vol. 25, no. 2, s. 383-417. Dostupné z: <https://doi.org/10.2307/2325486>. [citováno 2026-04-24].

FAMA, Eugene F., 1991. Efficient Capital Markets: II. Online. *The Journal of Finance*. Vol. 46, no. 5, s. 1575-1617. Dostupné z: <https://doi.org/10.1111/j.1540-6261.1991.tb04636.x>. [citováno 2026-04-24].

FARRELL, Hugh a O'CONNOR, Fergal, 2025. The CNN Fear and Greed Index as a predictor of US equity index returns: Static and time-varying Granger causality. Online. *Finance Research Letters*. Vol. 72, 106492. Dostupné z: <https://doi.org/10.1016/j.frl.2024.106492>. [citováno 2026-04-24].

FEDERAL RESERVE BANK OF ST. LOUIS [FRED], 2026. *ICE BofA US High Yield Index Option-Adjusted Spread (BAMLH0A0HYM2)*. Online, datová řada. Dostupné z: <https://fred.stlouisfed.org/series/BAMLH0A0HYM2>. [citováno 2026-04-24].

FINHACKER.CZ, 2026. *Fear and Greed Index: Historical Data and Chart*. Online, datová řada. Dostupné z: <https://www.finhacker.cz/en/fear-and-greed-index-historical-data-and-chart>. [citováno 2026-04-24].

GROSSMAN, Sanford J. a STIGLITZ, Joseph E., 1980. On the Impossibility of Informationally Efficient Markets. Online. *The American Economic Review*. Vol. 70, no. 3, s. 393-408. Dostupné z: <https://www.jstor.org/stable/1805228>. [citováno 2026-04-24].

HAN, Jiawei; KAMBER, Micheline a PEI, Jian, 2012. *Data Mining: Concepts and Techniques*. 3rd ed. Waltham: Morgan Kaufmann. ISBN 978-0-12-381479-1.

JEGADEESH, Narasimhan a TITMAN, Sheridan, 1993. Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency. Online. *The Journal of Finance*. Vol. 48, no. 1, s. 65-91. Dostupné z: <https://doi.org/10.1111/j.1540-6261.1993.tb04702.x>. [citováno 2026-04-24].

KAHNEMAN, Daniel a TVERSKY, Amos, 1979. Prospect Theory: An Analysis of Decision under Risk. Online. *Econometrica*. Vol. 47, no. 2, s. 263-291. Dostupné z: <https://doi.org/10.2307/1914185>. [citováno 2026-04-24].

KRESTA, Aleš, 2024. *Applied Quantitative Finance in Python: Selected Theories and Examples*. Online. Series of Economics Textbooks, Vol. 38. Ostrava: VŠB-TUO. ISBN 978-80-248-4748-1. Dostupné z: <https://doi.org/10.31490/9788024847481>. [citováno 2026-04-24].

LEMMON, Michael a PORTNIAGUINA, Evgenia, 2006. Consumer Confidence and Asset Prices: Some Empirical Evidence. Online. *The Review of Financial Studies*. Vol. 19, no. 4, s. 1499-1529. Dostupné z: <https://doi.org/10.1093/rfs/hhj038>. [citováno 2026-04-24].

LIUTVINAVIČIUS, Marius; ZUBOVA, Jelena a SAKALAIUSKAS, Virgilijus, 2017. Behavioural Economics Approach: Using Investors Sentiment Indicator for Financial Markets Forecasting. Online. *Baltic Journal of Modern Computing*. Vol. 5, no. 3, s. 275-294. Dostupné z: <https://doi.org/10.22364/bjmc.2017.5.3.03>. [citováno 2026-04-24].

LO, Andrew W., 2004. The Adaptive Markets Hypothesis: Market Efficiency from an Evolutionary Perspective. Online. *The Journal of Portfolio Management*. Vol. 30, no. 5, s. 15-29. Dostupné z: <https://doi.org/10.3905/jpm.2004.442611>. [citováno 2026-04-24].

MCCLELLAN FINANCIAL PUBLICATIONS, 2026. *The McClellan Oscillator & Summation Index*. Online. Dostupné z: https://www.mcclellan.com/learning_center/kb/mcclellan_oscillator/the_mcclellan_oscillator_summation_index/. [citováno 2026-04-24].

MCCLAVE, James T.; BENSON, P. George a SINCICH, Terry, 2017. *Statistics for Business and Economics*. 13th ed. Boston: Pearson. ISBN 978-0-13-450659-3.

MCKINNEY, Wes, 2022. *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. Third edition. Sebastopol: O'Reilly. ISBN 978-1-098-10403-0.

MORROW, Allison, 2025. *A brief history of CNN's Fear and Greed Index*, Online. CNN Business. 7. 4. 2025. Dostupné z: <https://edition.cnn.com/2025/04/07/business/what-is-cnn-fear-and-greed-index>. [citováno 2026-04-24].

PANDAS DEVELOPMENT TEAM, 2024. *pandas 2.2.3 documentation*. Online. Dostupné z: <https://pandas.pydata.org/pandas-docs/version/2.2.3/>. [citováno 2026-04-24].

ROSCOE, John T., 1975. *Fundamental Research Statistics for the Behavioral Sciences*. 2nd ed. New York: Holt, Rinehart and Winston. ISBN 0-03-091934-7.

SHILLER, Robert J., 2015. *Irrational Exuberance*. 3rd ed. Princeton: Princeton University Press. ISBN 978-0-691-16626-1.

STOCKCHARTS.COM, 2026. StockCharts.com. Online, datový zdroj. Dostupné z: <https://stockcharts.com/>. [citováno 2026-04-24].

WILLMOTT, Cort J. a MATSUURA, Kenji, 2005. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. Online. *Climate Research*. Vol. 30, s. 79-82. Dostupné z: <https://doi.org/10.3354/cr030079>. [citováno 2026-04-24].

YAHOO FINANCE, 2026. *Yahoo Finance*. Online, datový zdroj. Dostupné z: <https://finance.yahoo.com/>. [citováno 2026-04-24].

Seznam zkratek

AMEX	American Stock Exchange
AMH	Adaptive Markets Hypothesis
API	Application Programming Interface
BofA	Bank of America
BSI	Bullish Sentiment Index
CAGR	Compound Annual Growth Rate
CBOE	Chicago Board Options Exchange
CNN	Cable News Network
CPC	CBOE Total Put/Call Ratio
CPCE	CBOE Equity-Only Put/Call Ratio
CPCI	CBOE Index-Only Put/Call Ratio
EMH	Efficient Market Hypothesis
ETF	Exchange-Traded Fund
FGI	Fear & Greed Index
FGI_Equal	Varianta FGI s rovnoměrnými vahami
FGI_OLS	Varianta FGI s vahami odhadnutými metodou OLS
FRED	Federal Reserve Economic Data
GPT	Generative Pre-trained Transformer
ICE	Intercontinental Exchange
IPO	Initial Public Offering
IS	In-sample
LLM	Large Language Model
MA	Moving Average
MAE	Mean Absolute Error
MBE	Mean Bias Error
NASDAQ	National Association of Securities Dealers Automated Quotations
NYSE	New York Stock Exchange
OAS	Option-Adjusted Spread
OLS	Ordinary Least Squares
OOS	Out-of-sample
P90	Devadesátý percentil
S&P	Standard & Poor's
USA	United States of America
USD	United States Dollar
VIX	Volatility Index
VŠB-TUO	Vysoká škola báňská – Technická univerzita Ostrava

Seznam příloh

Příloha 1

Příloha 2

Příloha 1

Deklarace využití nástrojů umělé inteligence při zpracování diplomové práce

Při zpracování této diplomové práce byly podpůrně využity vybrané nástroje umělé inteligence, zejména při tvorbě zdrojového kódu a při jazykové a stylistické úpravě textu. Jejich využití nenahrazovalo vlastní odbornou, analytickou ani interpretační činnost autora. Metodologická rozhodnutí, výběr dat, konstrukce výzkumného postupu, interpretace výsledků i konečné závěry byly provedeny autorem práce.

Pro tvorbu, úpravu a kontrolu programového kódu byly využity nástroje Codex a Claude Code. Sloužily především jako pomoc při návrhu implementačních postupů, ladění chyb, kontrole skriptů, refaktoringu části kódu a řešení rutinních technických úloh souvisejících se zpracováním dat, konstrukcí indexu a backtestingem obchodních strategií. Výstupy těchto nástrojů nebyly přebírány automaticky. Výsledný kód byl autorem kontrolován, upravován a testován.

Při jazykové úpravě textu byly využity také velké jazykové modely Sonnet 4.6, GPT-5.4 a GPT-5.5. Tyto nástroje byly používány zejména ke kontrole gramatiky, stylistiky, zpřesnění formulací a úpravě autorem napsaných pasáží do soudržnější akademické podoby. Navržené úpravy byly vždy dále posuzovány a případně přepracovávány autorem tak, aby odpovídaly skutečnému obsahu práce i vlastní argumentaci.

Nástroje umělé inteligence byly využívány pouze jako pomocný prostředek. Za správnost použitých informací, konečnou podobu textu i kódu a odbornou úroveň diplomové práce odpovídá autor.

Příloha 2

Zdrojové kódy

Zdrojové kódy použité při zpracování empirické části diplomové práce jsou přiloženy jako samostatná příloha ve formátu ZIP. Kódy jsou současně dostupné také prostřednictvím veřejného repozitáře GitHub: <https://github.com/amlerdev/fgi-diploma-thesis>.